CESI

ÉCOLE D'INGÉNIEURS

Bloc Stockage et Big Data
PGE A4 FISA / A3 FISE Big Data, promotion 2026-2027

PROJET CLOUD HEALTHCARE UNIT

Livrable 1 : rapport écrit

Référentiel de données et architecture cible

Entrepôt de données décisionnel (EDD) du groupe CHU :
modèle conceptuel et logique, architecture Bronze / Silver / Gold sur HDFS et Hive, jobs Talend, spécifications ETL et plan de gouvernance des données de santé

Auteurs	Tony Fages, Martin Caparros, David d'Almeida
Version / date	2.6 du 26 octobre 2026 (version remise)
Destinataires	Équipe pédagogique du bloc ; maîtrise d'ouvrage (direction du groupe CHU) ; DPO ; RSSI
Données analysées	Dump PostgreSQL `DATA2023` (13 tables) et `Hospitalisations.csv` ; échantillons de l'annuaire santé ; fichiers HAS e-Satis et IQSS 2014-2020 ; échantillon du fichier INSEE des décès

Table des matières

1 Introduction **1**

2 Modèle conceptuel et logique du schéma décisionnel **1**

2.1 Grains et matrice en bus 1

2.2 Modèle conceptuel de données (MCD) 1

2.3 Modèle logique : schémas en étoile 2

2.4 Clés de substitution et membres spéciaux 2

3 Architecture cible **7**

3.1 Vue d'ensemble et couches Bronze/Silver/Gold 7

3.2 Hiérarchie du datalake et tables Hive 8

3.3 Technologies retenues et justification 8

3.4 Flux de données de bout en bout 8

4 Spécifications fonctionnelles des jobs ETL **10**

4.1 Sources, principes et contextes 10

4.2 Jobs et fréquence d'exécution 11

4.3 Conception des jobs de dimensions et de faits 11

4.4 Règles de transformation 13

4.5 Valeurs nulles, doublons, erreurs et rejets 13

5 Plan de gouvernance des données **14**

5.1 Conformité RGPD et conformité HDS 14

5.2 Pseudonymisation, anonymisation et zones de sécurité 15

5.3 Rôles et droits d'accès, traçabilité des flux 15

5.4 Conservation, droits et incidents 15

A Dictionnaire de données **18**

1 Introduction

Le groupe CHU souhaite un entrepôt de données décisionnel (EDD) unifiant quatre sources hétérogènes : une base PostgreSQL opérationnelle (S1), des fichiers CSV de l'annuaire santé (S2), des fichiers de satisfaction HAS accessibles par FTP (S3) et le fichier des décès de l'INSEE (S4).

Ce livrable 1 présente les quatre composantes demandées : le modèle conceptuel et logique du schéma décisionnel (chapitre 2), l'architecture cible Bronze/Silver/Gold avec les technologies retenues (chapitre 3), les spécifications fonctionnelles des jobs ETL (chapitre 4) et le plan de gouvernance des données (chapitre 5). Le dictionnaire de données complet est en annexe A.

2 Modèle conceptuel et logique du schéma décisionnel

2.1 Grains et matrice en bus

Le modèle suit l'approche Kimball : quatre processus métiers (consultation, hospitalisation, décès, satisfaction), chacun modélisé par une table de faits entourée de dimensions. Le grain retenu est le plus fin disponible dans les sources.

Table 2.1 : Processus, grain et type de fait

Processus	Grain	Type	Besoins couverts
Consultation	Une consultation (`Num_consultation`)	Transactionnel	Taux de consultation par établissement, par diagnostic, par professionnel
Hospitalisation	Un séjour (entrée et durée)	Transactionnel	Taux d'hospitalisation global, par diagnostic, par sexe et âge
Décès	Un acte de décès dédoublonné	Transactionnel	Nombre de décès par région
Satisfaction	Un résultat d'indicateur par établissement et campagne	Instantané annuel	Taux de satisfaction par région

Quatre faits distincts sont nécessaires car les grains sont incompatibles : le décès n'a pas de patient (open data sans appariement), le résultat HAS est un agrégat publié. Les dimensions conformes (tableau 2.2) relient les quatre faits pour les analyses croisées.

2.2 Modèle conceptuel de données (MCD)

Le MCD Merise est présenté en deux vues reliées par l'entité ÉTABLISSEMENT (figures 2.1 et 2.2). Règles : RG-M01, une consultation a un seul patient, professionnel, diagnostic et mutuelle ; RG-M02, un séjour a un seul patient, établissement et diagnostic ; RG-M03, un professionnel exerce dans 0 à n établissements ; RG-M04, un établissement est dans 0 ou 1 commune ; RG-M05, un décès survient dans une commune ou à l'étranger ; RG-M06, l'association ternaire MESURER devient `fait_indicateur_qualite`.

Table 2.2 : Matrice en bus (processus × dimensions)

Processus	*Date*	*Patient*	*Sexe*	*Tranche d'âge*	*Établissement*	*Géographie*	*Diagnostic*	*Professionnel*	*Mutuelle*	*Acte*	*Campagne*	*Indicateur*
Consultation	✓	✓	✓	✓	✓	✓[E]	✓	✓	✓	✓		
Hospitalisation	✓ ×2	✓	✓	✓	✓	✓[E]	✓					
Décès	✓		✓	✓		✓[D]						
Satisfaction / qualité	✓[R]				✓	✓[E]					✓	✓
Conforme ?	oui	oui	oui	oui	oui	oui*	oui	non	non	non	non	non

×2 : double rôle (entrée, sortie). [R] : `date_reference_sk`, 1er janvier de l'année des données. Rôles de `dim_geographie` : [E] lieu de l'établissement, [D] lieu du décès. * Résidence du patient et géographie de l'établissement reprennent ses codes.

2.3 Modèle logique : schémas en étoile

La constellation (figure 2.3) montre les quatre faits et les dimensions partagées. Le dictionnaire complet (16 tables, 163 attributs, 27 clés étrangères) est en annexe A.

Cardinalités. Toute clé étrangère d'un fait est non nulle (membres spéciaux) et référence une seule ligne de dimension : cardinalité (1,1) côté fait, (0,n) côté dimension, soit une relation N:1 (tableau 2.3). Pour les dimensions SCD 2, la clé durable porte 1 à n versions ; le fait pointe la version en vigueur à la date de l'événement.

Table 2.3 : Cardinalités des clés étrangères par étoile, (1,1) côté fait et (0,n) côté dimension

Fait (étoile)	Dimensions référencées (préfixe `dim_`), chacune en N:1
`fait_consultation` (10 FK)	`date`, `patient`, `professionnel`, `etablissement`, `geographie`, `diagnostic`, `mutuelle`, `acte`, `sexe`, `tranche_age`
`fait_hospitalisation` (8 FK)	`date` ×2, `patient`, `etablissement`, `geographie`, `diagnostic`, `sexe`, `tranche_age`
`fait_deces` (4 FK)	`date`, `geographie`, `sexe`, `tranche_age`
`fait_indicateur_qualite` (5 FK)	`etablissement`, `campagne`, `indicateur`, `date`, `geographie`

2.4 Clés de substitution et membres spéciaux

Chaque dimension possède une clé entière automatique (suffixe `_sk`), distincte de la clé source, stable d'un chargement à l'autre. `dim_date` utilise la clé `AAAAMMJJ`. Une clé étrangère de fait n'est jamais `NULL` : elle pointe vers un membre spécial.

Additivité : les comptes (`nb_*`) et durées sont additifs ; âges et scores ne le sont pas (moyenne pondérée par `effectif_base`) ; les patients distincts se recomptent, jamais ne se somment.

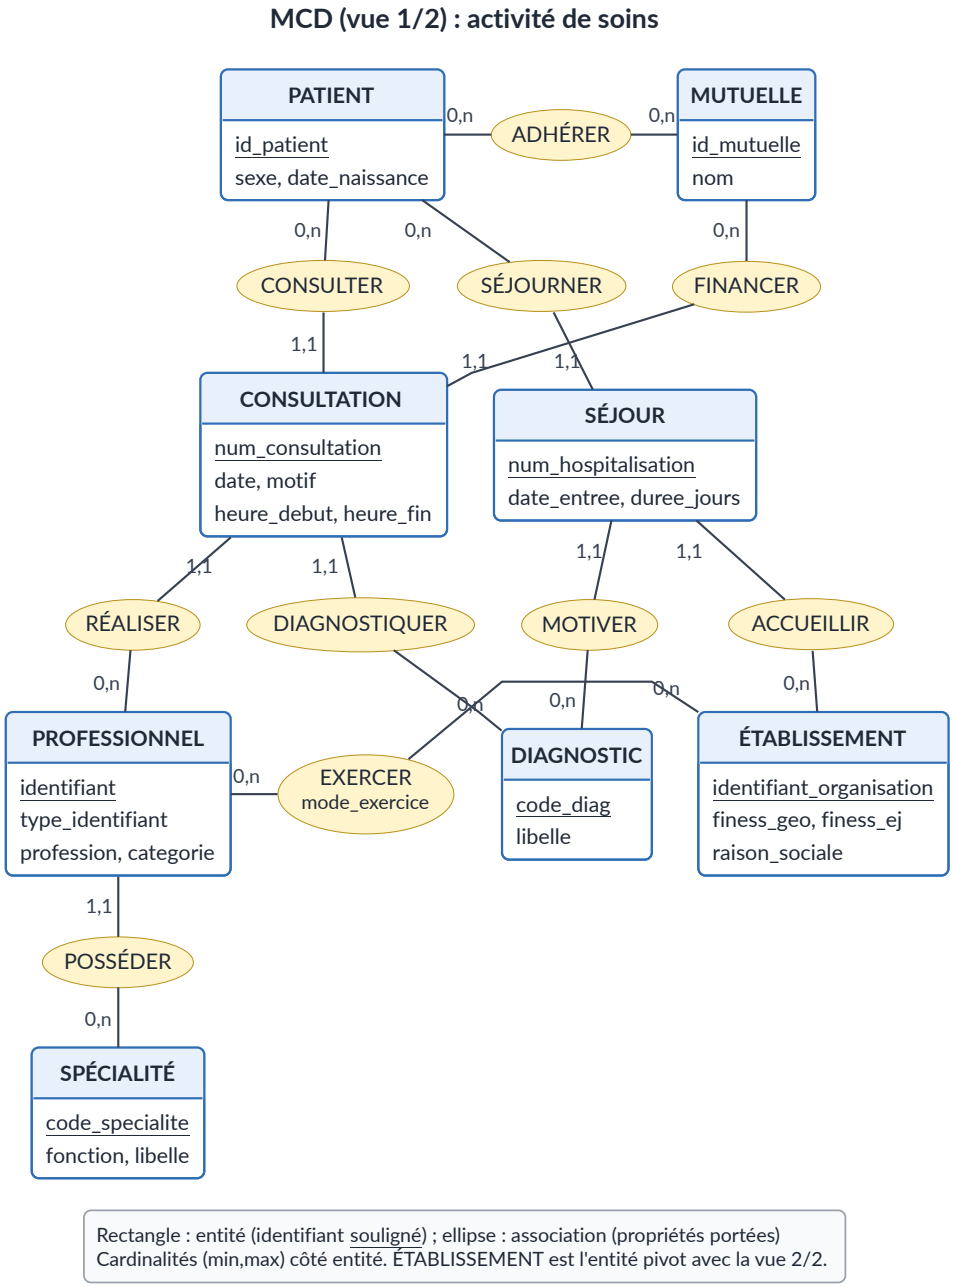


Figure 2.1 : MCD (vue 1/2), activité de soins

Table 2.4 : Membres spéciaux

Clé	Libellé	Dimensions	Usage
-1	Inconnu	Toutes	Valeur absente dans la source.
-2	Non applicable	`dim_date`	Attribut sans objet.
-3	Hors référentiel	`dim_diagnostic`, `dim_geographie`, `dim_etablissement`	Code présent mais absent du référentiel ; valeur brute gardée en Silver.
-4	Non déterminable	`dim_etablissement`	La règle de dérivation ne conclut pas (consultation sans activité rattachée).

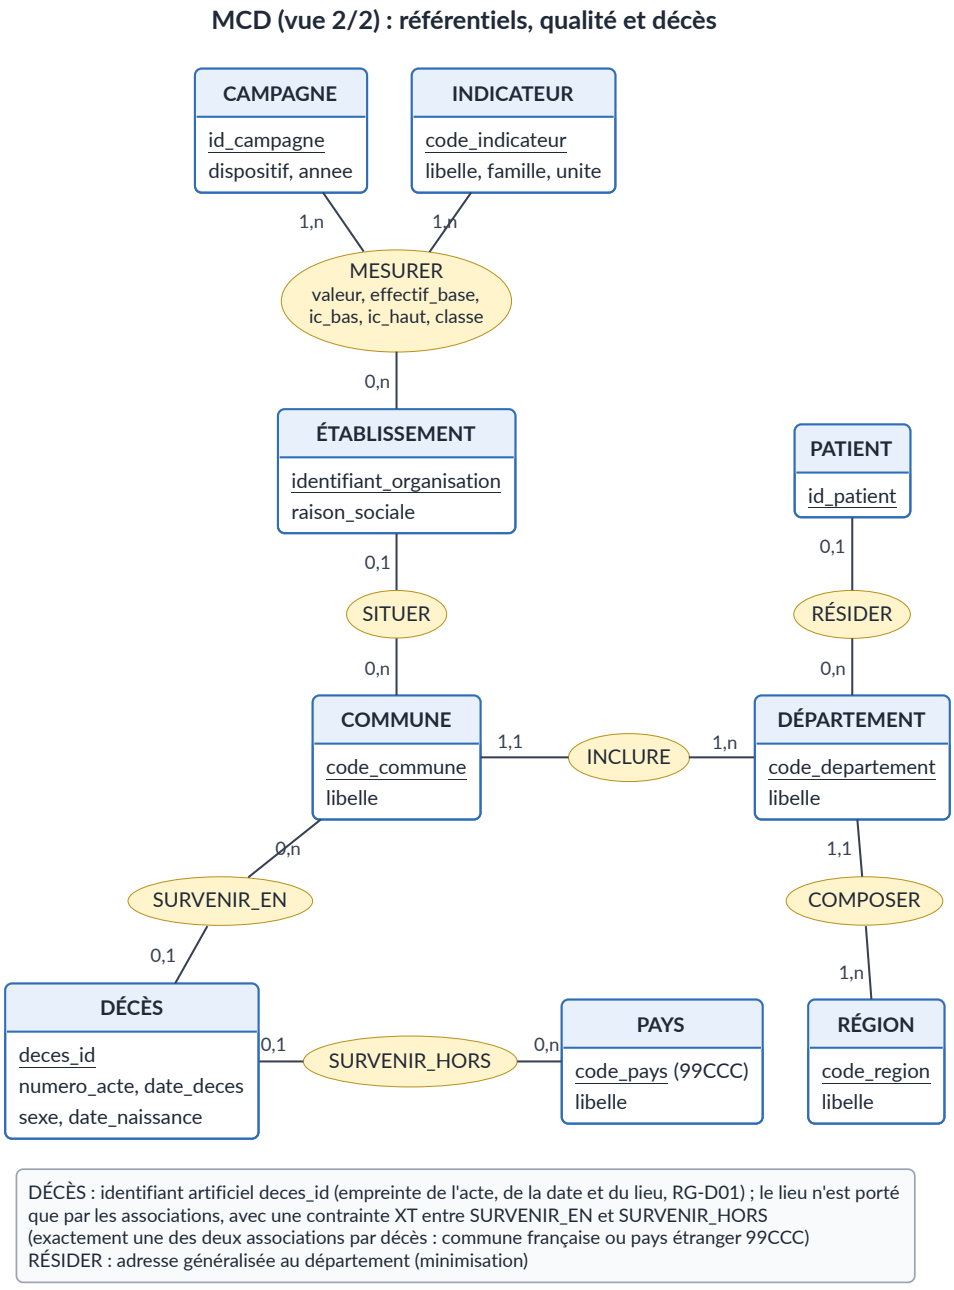


Figure 2.2 : MCD (vue 2/2), référentiels, qualité et décès

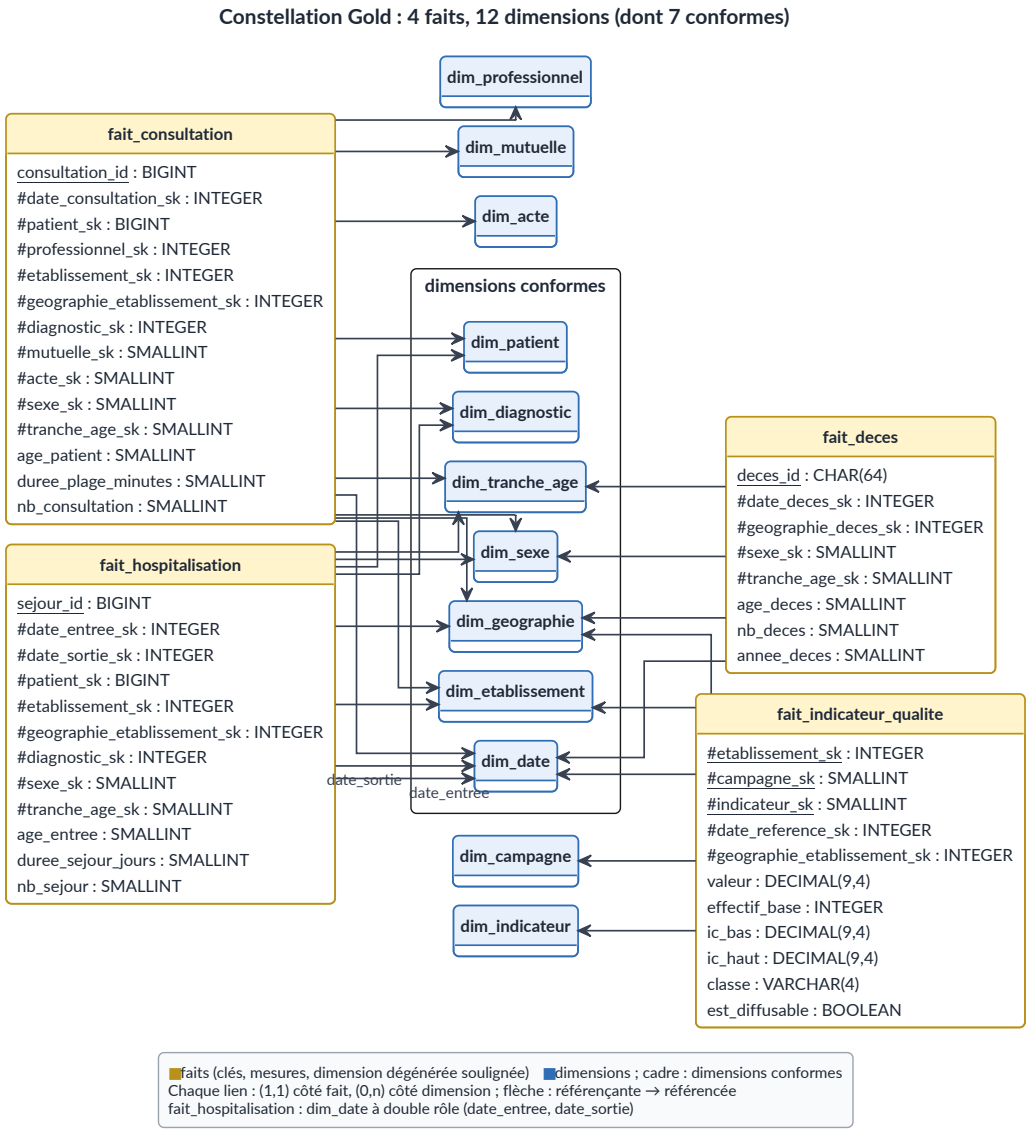


Figure 2.3 : Constellation de faits de la couche Gold

Table 2.5 : Historisation des dimensions (SCD)

Dimension	Type	Justification
`dim_etablissement`	2 (raison sociale, commune, entité juridique, catégorie)	Un acte reste attribué à l'établissement tel qu'il était ; clé durable `identifiant_organisation`.
`dim_professionnel`	2 (profession, spécialité, mode d'exercice)	Version en vigueur à la date de l'acte ; clé durable `professionnel_pseudo`.
`dim_patient`, référentiels	1	Valeur actuelle.
Date, sexe, tranche, acte, campagne	Statique	Générées ou observées.

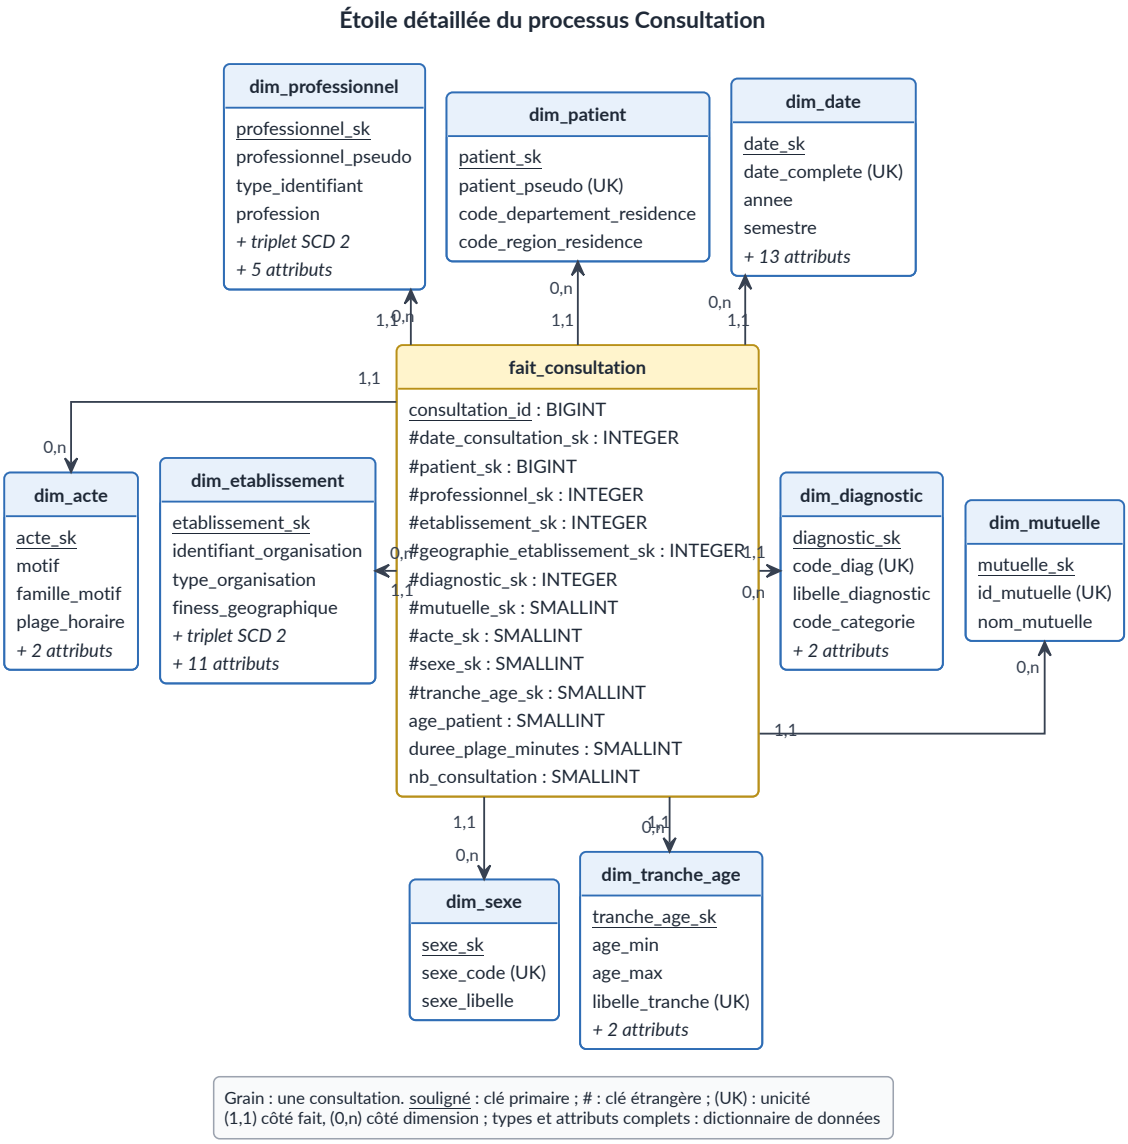


Figure 2.4 : MLD du processus Consultation (schéma en étoile)

3 Architecture cible

3.1 Vue d'ensemble et couches Bronze/Silver/Gold

L'architecture retenue est un datalake HDFS organisé en trois couches médaillon, sur le cluster Cloudera du bloc : **Bronze** (`chu_bronze`) copie fidèle des extractions, un répertoire par chargement jamais modifié ; **Silver** (`chu_silver`) données typées, dédoublonnées, conformées et pseudonymisées ; **Gold** (`chu_gold`) constellation en étoile et vues agrégées, publiée par bascule contrôlée.

Le poste Windows porte Talend Open Studio for Big Data 7.3.1, PostgreSQL (`DATA2023`) et Power BI Desktop. La VM Cloudera QuickStart 5.12 porte HDFS, Hive, Hue et YARN. Talend accède au cluster par une métadonnée *Cluster Hadoop* (distribution Cloudera) et des connexions HDFS et Hive.

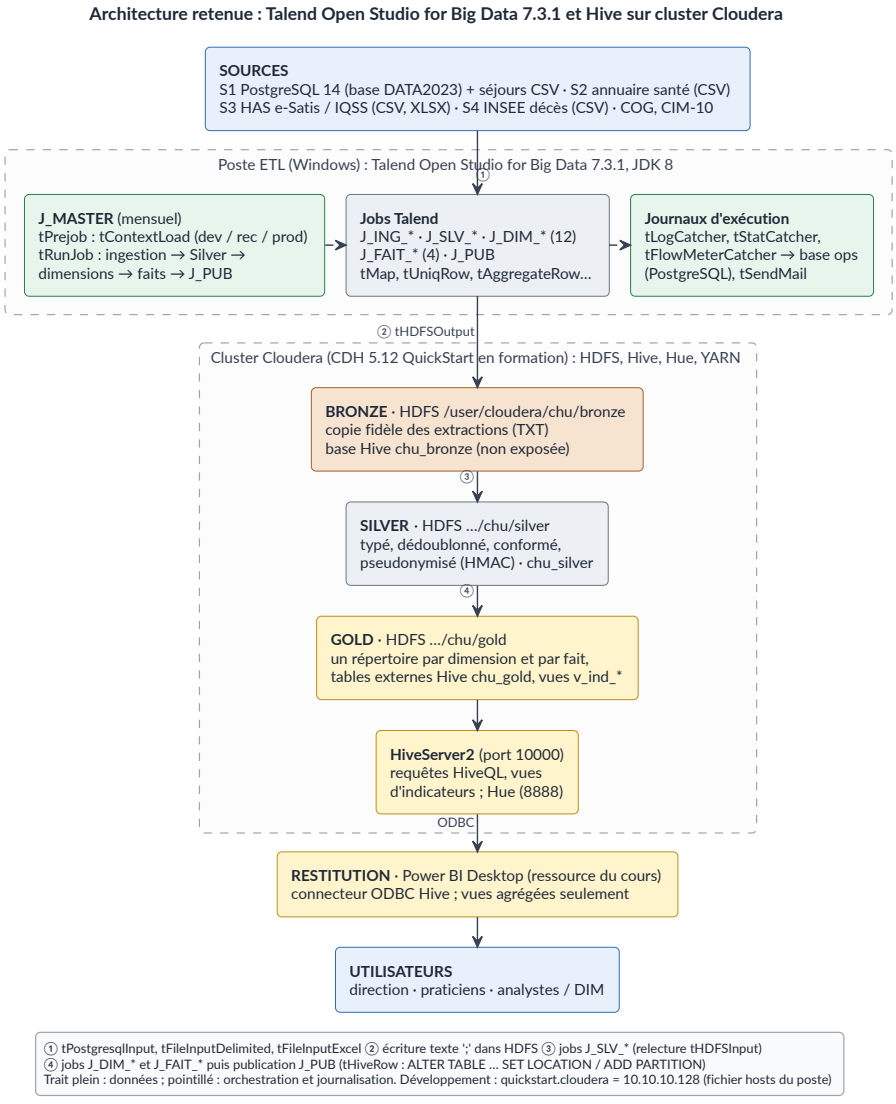


Figure 3.1 : Architecture retenue (jobs Talend, datalake HDFS en médaillon, tables externes Hive, Power BI)

3.2 Hiérarchie du datalake et tables Hive

Racine en variable de contexte (`hdfs_racine`), puis couche, table, chargement mensuel :

```
/user/cloudera/chu/                    racine = context.hdfs_racine
  bronze/ s1_patient/ s1_consultation/ s1_professionnel/ s1_diagnostic/ s1_mutuelle/
          s1_specialites/ s1_hospitalisation/ s2_etablissement/ s2_activite/
          s3_fichier/ s4_deces/ ref_cog/ ref_cim10/  (chacun : chargement=AAAAMM/)
  silver/ slv_<entite>/chargement=AAAAMM/      rejet/chargement=AAAAMM/
  gold/   dim_date/ dim_patient/ dim_sexe/ dim_tranche_age/ dim_geographie/
          dim_etablissement/ dim_diagnostic/ dim_professionnel/ dim_mutuelle/
          dim_acte/ dim_campagne/ dim_indicateur/
          fait_consultation/ fait_hospitalisation/ fait_deces/ fait_indicateur_qualite/
          (chacun : chargement=202610/  chargement=202611/  ...)
```

Justification de la hiérarchie :

1. **Un répertoire par dimension et par fait** : une table externe Hive lit tous les fichiers de son `LOCATION` ; un répertoire propre à chaque table permet de charger, rejouer ou purger une dimension sans toucher aux autres.
2. **Un sous-répertoire par chargement** (`chargement=AAAAMM`) : le mois en cours s'écrit sans toucher au mois publié ; la publication et le retour arrière sont des bascules de métadonnées.
3. **Table externe, jamais interne** : la supprimer ne supprime pas ses fichiers ; une erreur de DDL ne détruit pas de données.
4. **Une couche par répertoire de premier niveau** : droits HDFS et base Hive par couche.

Format et partitionnement. Texte délimité (`TEXTFILE`, `;`, UTF-8) : lisible par les tables externes Hive, écrit par `tHDFSOutput`, contrôlable dans Hue. Champ vide = `NULL` ; dates `yyyy-MM-dd`. Seuls les trois faits alimentés par ajout sont partitionnés, par `chargement`.

Listing 3.1 : Extrait du DDL HiveQL généré et publication d'un chargement

```
CREATE EXTERNAL TABLE IF NOT EXISTS dim_patient (patient_sk BIGINT,
  patient_pseudo VARCHAR(64), code_departement_residence VARCHAR(3),
  code_region_residence VARCHAR(2), id_lot VARCHAR(36), dt_chargement TIMESTAMP)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ';' NULL DEFINED AS '' STORED AS TEXTFILE
LOCATION '${hivevar:racine}/gold/dim_patient/chargement=${hivevar:chargement}';
ALTER TABLE dim_patient SET LOCATION '<racine>/gold/dim_patient/chargement=202611';
ALTER TABLE fait_consultation ADD IF NOT EXISTS PARTITION (chargement='202611')
  LOCATION '<racine>/gold/fait_consultation/chargement=202611';
```

3.3 Technologies retenues et justification

Compromis acceptés. Talend Open Studio (édition gratuite) n'est plus maintenu depuis janvier 2024 : les jobs sont exportés et versionnés, les règles de transformation sont indépendantes de l'outil. Hive en `TEXTFILE` n'offre ni transactions ni `UPDATE` : la cohérence est assurée par les répertoires de chargement et la bascule contrôlée. Power BI : le connecteur Hive natif est déprécié, d'où le pilote ODBC.

3.4 Flux de données de bout en bout

Le job maître `J_MASTER`, mensuel, enchaîne ingestion (Bronze), transformations (Silver), 12 dimensions, 4 faits et publication (figure 3.2). Dimensions avant faits, portes de qualité par source.

Table 3.1 : Technologies retenues par brique, avec justification

Brique	Retenu	Justification
ETL	**Talend Open Studio for Big Data 7.3.1**	Outil imposé par l'environnement du bloc ; composants HDFS, Hive et PostgreSQL natifs ; contextes dev/rec/prod ; `tMap` pour jointures et SCD 2. Alternative libre : Apache NiFi (ingestion) ou dbt (transformations SQL).
Stockage	**HDFS + Hive (tables externes)**	Datalake en couches sur le cluster Cloudera du bloc ; montée en charge horizontale ; tables externes sur fichiers texte. Alternative : PostgreSQL (transactions, mais un seul nœud) ou BigQuery (managé, mais hors UE).
BI	**Power BI Desktop**	Outil du cours ; modélisation et visuels riches ; RLS dans le service en ligne. Connexion à HiveServer2 par pilote ODBC Hive, mode *Import* sur vues agrégées. Alternative : Metabase ou Apache Superset.

Publication (Write-Audit-Publish) : chaque job Gold écrit dans `gold/<table>/chargement=AAAAMM/` ; `J_PUB` crée une table de travail sur ce répertoire, y exécute les contrôles par `tHiveRow`, puis bascule par `SET LOCATION` (dimensions) ou `ADD PARTITION` (faits). En cas d'échec, rien ne bascule ; le retour arrière se fait par `SET LOCATION` ou `DROP PARTITION`.

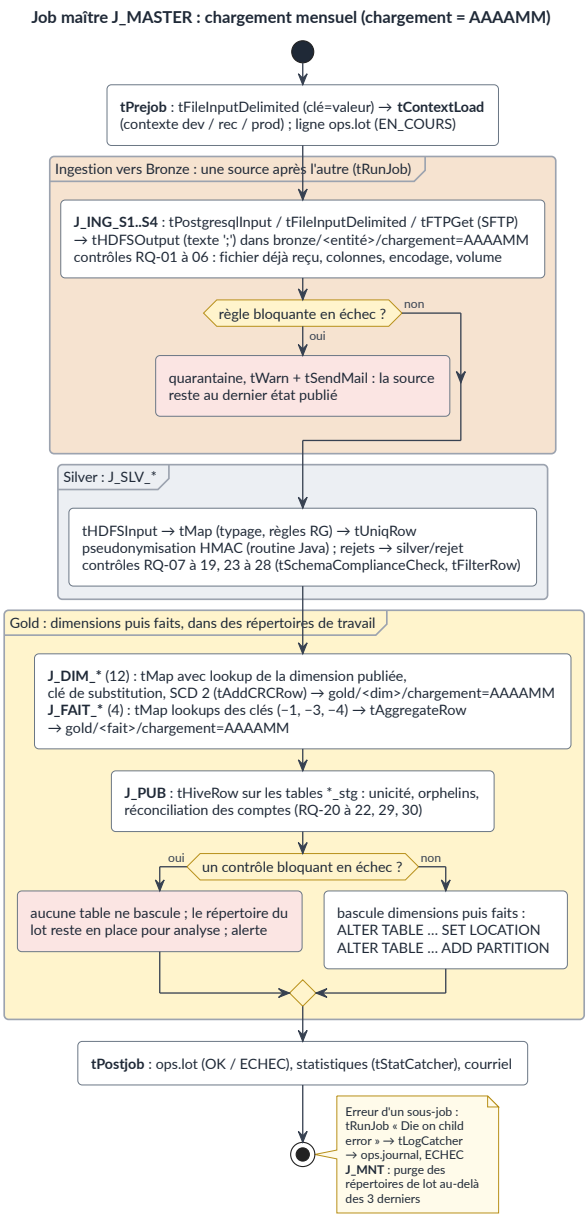


Figure 3.2 : Job maître mensuel (portes de qualité par source, contrôles puis bascule des tables Hive)

4 Spécifications fonctionnelles des jobs ETL

Chaîne de type ELT : chargement brut dans HDFS (Bronze), transformations en Silver, puis chargement dans les tables Gold. Un job Talend par dimension et par fait, orchestré par un job maître mensuel.

4.1 Sources, principes et contextes

Sources : S1 (PostgreSQL `DATA2023`), séjours (CSV `Hospitalisations`), S2 (annuaire santé, 3 CSV), S3 (fichiers HAS), S4 (décès INSEE), et référentiels (COG, CIM-10). **Lot** : variable `chargement = AAAAMM`. **Idempotence** : écriture en mode *Overwrite* dans `<couche>/<table>/chargement=AAAAMM/`. **Nulls** : jamais de `NULL` dans une clé étrangère de fait (membres spéciaux) ; mesure inconnue = `NULL`,

jamais 0. **Ordre** : dimensions avant faits.

4.1.1 Contextes Talend

Un **groupe de contextes** `CTX_CHU` porte les trois environnements `dev`, `rec` et `prod`. Les métadonnées de connexion (PostgreSQL, cluster Hadoop, HDFS, Hive) y sont liées par « exporter en tant que contexte ». Chaque job importe le groupe et n'utilise que des variables de contexte.

Table 4.1 : Variables du groupe de contextes `CTX_CHU`

Variable	Type	dev (poste et VM QuickStart)	rec, prod
`pg_host`, `pg_port`, `pg_base`, `pg_user`, `pg_password`	String, int, Password	`localhost`, `5432`, `DATA2023`, compte local	serveur PostgreSQL du CHU, lecture seule
`hdfs_uri`	String	`hdfs://quickstart.cloudera:8020`	NameNode du cluster
`hdfs_racine`	String	`/user/cloudera/chu`	`/data/chu` (proposé)
`hive_host`, `hive_port`, `hive_base`, `hive_user`	String, int	`quickstart.cloudera`, `10000`, `chu_gold`, `cloudera`	HiveServer2 ; compte de service
`ops_jdbc`, `ops_user`, `ops_password`	String, Password	base `ops` locale	base d'exploitation
`chargement`	String	`AAAAMM`, mois précédent par défaut	idem
`hmac_cle_patient`, `hmac_cle_prof`	Password	clé de test	fichier protégé

Utilisation dans un job. Le contexte se choisit dans l'onglet *Run* ; `tRunJob` transmet celui du job maître (« Transmit whole context »). Exemple : `tPostgresqlInput` lit `context.pg_host`, `pg_port`, `pg_base`, `pg_user`, `pg_password` ; `tHDFSOutput` écrit dans `context.hdfs_racine + "/gold/dim_patient/chargement=" + context.chargement`.

4.2 Jobs et fréquence d'exécution

Fréquence : mensuelle pour chaque dimension et chaque fait. `J_MASTER`, planifié chaque mois, charge le mois précédent.

4.3 Conception des jobs de dimensions et de faits

Clé de substitution automatique. Chaque dimension a une clé entière automatique (suffixe `_sk`), distincte de la clé source : un `tMap` cherche la clé métier dans la dimension publiée (lookup) et reprend sa clé, sinon `max_sk + Numeric.sequence("sk", 1, 1)`. Une clé n'est jamais réattribuée. Les membres spéciaux (-1 à -4) sont ajoutés par `tFixedFlowInput` et `tUnite`.

J_DIM_PATIENT (champs pertinents seulement). Lecture de `SELECT "Id_patient", "Sexe", "Date", "Code_postal" FROM "Patient"`. Calcul du pseudonyme `patient_pseudo` (HMAC-SHA-256). Déduction du département et de la région du code postal. Clé `patient_sk`. Type 1 (écrasement mensuel).

J_DIM_PROFESSIONNEL (jointure avec l'annuaire S2). Lecture de `Professionnel_de_sante` et `Specialites` de S1, jointure avec `activite_professionnel_sante.csv` de l'annuaire sur l'identi-

Table 4.2 : Jobs Talend : un par source, un par dimension, un par fait

Job	Source → répertoire	Traitement
J_ING_S1	S1 (PostgreSQL) → bronze/s1_*	tPostgresqlInput (colonnes utiles) → tHDFSOutput ; incrémental
J_ING_S1H, J_ING_S2	Séjours, annuaire (3 CSV)	tFileInputDelimited (CP1252 pour S2) → tHDFSOutput
J_ING_S3, J_ING_S4	HAS, décès INSEE	tFileList, tFileInputDelimited / tFileInputExcel ; S4 : noms non lus
J_SLV_* (6)	Bronze → silver/slv_*	tHDFSInput, tMap (règles RG), tUniqRow, HMAC, rejets → silver/rejet
J_DIM_DATE	Dates des 4 sources → gold/dim_date	Mensuel, voir §4.3
J_DIM_PATIENT	slv_patient → gold/dim_patient	Mensuel, type 1, voir §4.3
J_DIM_PROFESSIONNEL	slv_professionnel + activités S2 → gold/dim_professionnel	Mensuel, SCD 2, voir §4.3
J_DIM_ETABLISSEMENT	slv_etablissement → gold/dim_etablissement	SCD 2
J_DIM_DIAGNOSTIC	S1, séjours, CIM-10 → gold/dim_diagnostic	Mensuel, voir §4.3
J_DIM_GEOGRAPHIE	COG + lieux des sources → gold/dim_geographie	Mensuel, voir §4.3
J_DIM_MUTUELLE, J_DIM_ACTE	slv_mutuelle ; motifs et plages	tMap, tUniqRow ; clé automatique
J_DIM_SEXE, J_DIM_TRANCHE_AGE	Listes fixes	tFixedFlowInput ; membres spéciaux
J_DIM_CAMPAGNE, J_DIM_INDICATEUR	Fichiers HAS	tFileList, tMap
J_FAIT_* (4)	Silver + dimensions → gold/fait_*	Voir §4.3
J_PUB, J_MNT	Tables de travail ; répertoires	tHiveRow (contrôles, bascule) ; tHDFSDelete
J_MASTER	Enchaînement	Voir §4.3.2

fiant normalisé (ADELI 9 chiffres, RPPS 11). Récupération des établissements d'exercice et du mode d'exercice. SCD type 2 (§4.3.1).

J_DIM_DIAGNOSTIC (données de plusieurs sources). Trois flux réunis par tUnite : table Diagnostic de S1 (libellé de référence), Code_diag des consultations, colonne Code_diagnostic du fichier des séjours. Le fichier établissement (S2, annuaire) ne comporte pas de colonne de diagnostic. Normalisation du code (majuscules, sans point). Lookup CIM-10 pour chapitre et catégorie.

J_DIM_GEOGRAPHIE (jointure des lieux des sources). Référentiel COG et table de passage. Lieux observés réunis : commune des établissements S2 (situe aussi consultations, séjours et satisfaction), code_lieu_deces de S4, code postal des patients. Si code_commune vide : fusion cedex + commune rapprochés du COG. Lieu introuvable → membre -3.

J_DIM_DATE (jointure des dates des sources). Dates réunies des quatre sources : consultation, entrée et sortie de séjour, décès, et année des données de satisfaction rattachée au AAAA0101. Génération de chaque jour jusqu'à la fin de l'année suivante. Calcul de l'année, mois, semaine ISO,

jour férié, jour ouvré. Clé `date_sk` = `AAAAMMJJ`, plus le membre -1.

Faits. Même patron pour les quatre jobs : lecture Silver, `tMap` avec un lookup par dimension, clé absente $\rightarrow$ membre spécial, mesures, écriture dans le répertoire du chargement. **Grain = l'événement.**

- `J_FAIT_CONSULTATION` : consultations du mois, version du professionnel en vigueur à la date de l'acte, établissement, âge et tranche.
- `J_FAIT_HOSPITALISATION` : fichier complet, sortie = entrée + durée, `nb_hospitalisation` = 1.
- `J_FAIT_DECES` : fichier mensuel INSEE, `deces_id` (SHA-256), dédoublonnage contre les actes déjà chargés.
- `J_FAIT_INDICATEUR_QUALITE` : S3 en clé-valeur, agrégation par (établissement, campagne, indicateur).

4.3.1 Historisation SCD 2 dans Talend

`tPostgresqlSCD` ne gère pas les fichiers HDFS : le SCD 2 de `dim_etablissement` et `dim_professionnel` est une réécriture complète dans un `tMap` :

1. flux principal : Silver du mois avec empreinte des attributs de type 2 (`tAddCRCRow`) ; lookup : versions courantes de la dimension publiée, jointes sur la clé durable ;
2. sorties : *inchangé* (empreintes égales), *nouveau* (nouvelle clé, début au 1900-01-01), *modifié* (ancienne version close, nouvelle version ouverte au premier jour du mois chargé) ;
3. les versions déjà closes et les objets absents du mois sont recopiés ; RQ-22 vérifie une seule version courante par clé, sans trou ni chevauchement.

4.3.2 Job maître et gestion des erreurs

`J_MASTER` : `tPrejob` (contexte, lot `EN_COURS`) ; chaîne de `tRunJob` (ingestion $\rightarrow$ Silver $\rightarrow$ dimensions $\rightarrow$ faits $\rightarrow$ `J_PUB`) reliés par *OnSubjobOk* ; `tPostjob` (statut, courriel). **Erreur bloquante** : « Die on child error » arrête la chaîne de la source ; `J_PUB` ne bascule que les groupes dont tous les lots sont `OK`. **Rejets** : sorties *reject* $\rightarrow$ `silver/rejet` ; exception au-delà du seuil. **Reprise** : relancer `J_MASTER` pour le même mois ; idempotent.

4.4 Règles de transformation

RG-C04 : rattachement d'une consultation à un établissement

Soit $A(p)$ les activités à organisation renseignée du professionnel p en vigueur à la date de l'acte : $|A(p)| = 0 \rightarrow -4$ (non déterminable) ; $|A(p)| = 1 \rightarrow$ cette organisation ; $|A(p)| > 1 \rightarrow$ ordre déterministe : groupe CHU, puis type F avant C, salarié avant libéral, plus petit identifiant.

4.5 Valeurs nulles, doublons, erreurs et rejets

Valeurs nulles : membres spéciaux pour les clés étrangères, `NULL` pour une mesure inconnue. **Doublons** : fichier déjà reçu ignoré ; ligne identique gardée une fois ; même clé dans un lot, dernière ligne gardée. **Erreurs et rejets**, trois sévérités : **bloquant lot** (rien n'est publié pour la source), **bloquant ligne** (ligne en rejet avec code de règle), **avertissement** (ligne chargée, anomalie comptée). La table `ops.lot` garde par lot les comptes lus, chargés, rejetés et doublons (lus = chargés + rejetés + doublons).

Table 4.3 : Règles de transformation par domaine (jobs `J_SLV_*`)

Domaine	Règles
Patient	**P01** `patient_pseudo` = HMAC-SHA-256 de `Id_patient` ; **P02** date de naissance analysée, Silver restreint seulement ; **P04** sexe → 1/2/9 ; **P05** code postal → département, région ; **P06** identité jamais extraite.
Professionnel	**R01** identifiant en texte, ADELI sur 9 chiffres, RPPS 11 ; **R02** pseudonyme HMAC ; **R03** spécialité ; **R04** mode d'exercice ; **R05** orphelin en quarantaine.
Consultation	**C01** dédoublonnage sur `Num_consultation` ; **C02** date rejetée si hors période ; **C03** patient par pseudonyme ; **C04** établissement déduit de l'activité du professionnel ; **C05** diagnostic normalisé, hors CIM-10 → -3, vide → -1 ; **C06** âge révolu, hors [0 ;120] → `NULL` ; **C07** mutuelle de l'acte ; **C08** acte = motif × plage.
Établissement	**E01** type et FINESS extraits de l'identifiant ; **E02** FINESS en texte ; **E03** commune vide → `cedex` + `commune` rapprochés du COG ; **E04** catégorie, périmètre ; **E05** diagnostics = référentiel S1 ∪ consultations ∪ séjours ; **E06** lieu = commune de l'établissement.
Séjour, HAS, décès	**H01 à H04** pseudonyme commun, entrée `JJ/MM/AAAA`, sortie = entrée + durée, établissement à l'entrée. **S01 à S05** dépivotage par `map_colonne_has`, « F » + `finess_geo`, classes DI/NR/NV, année lue dans le nom, région de l'établissement. **D01 à D05** `deces_id` = SHA-256, date partielle → -1, âge hors [0 ;125] → `NULL`, commune reprojetée sur le COG, naissance supprimée.
Transverse	**T01** encodage vérifié et réparé ; **T02** vides → `NULL`, NFC ; **T03** ; et retours à la ligne retirés, dates `yyyy-MM-dd`.

Table 4.4 : Catalogue des règles de qualité (B Bronze, S Silver, G Gold avant publication)

Règles	Cou.	Contrôle	Sévérité
RQ-01 à 06	B	Fichier déjà reçu ; colonnes conformes ; encodage ; volume ±20 % ; fraîcheur	Bloquant lot
RQ-07, 08	S	Format de date ; clé unique et non nulle	Bloquant ligne
RQ-09 à 12	S	Cohérence âge/naissance, sexe, mutuelle	Avertissement
RQ-10, 14	S	Activité orpheline ; identifiant professionnel	Quarantaine ; bloquant ligne
RQ-13, 19	S	Diagnostic CIM-10 ; commune résolue	Avertissement, -3
RQ-15 à 18	S	Durée de plage, dates, FINESS/SIRET	Avertissement ; bloquant ligne
RQ-23 à 27	S	Plages HAS, taux résolution FINESS ≥ 95 %, unicité décès	Bloquant ligne ; avertissement
RQ-28	S	Taux de résolution du rattachement établissement	Alerte sous 70 %
RQ-20 à 22	G	Clés étrangères présentes ; types ; SCD 2 sans trou ni chevauchement	Bloquant publication
RQ-29, 30	B, S, G	Réconciliation des comptes ; aucun identifiant direct	Bloquant publication

5 Plan de gouvernance des données

5.1 Conformité RGPD et conformité HDS

Hébergement de données de santé (HDS). La production exige un hébergeur certifié HDS (CSP, art. L. 1111-8) pour les activités 1 à 4 et 6. Le référentiel HDS v2 est applicable depuis le 16 mai 2026. Le décret n° 2026-209 impose un stockage exclusivement dans l'UE/EEE et quinze mentions contractuelles (art. R. 1111-11). Contre le risque extraterritorial : clés détenues par le CHU, option

Table 5.1 : Qualification RGPD du traitement « entrepôt de pilotage »

Élément	Analyse
Responsable	Selon la forme juridique du groupe CHU : directeur d'établissement public (CSP, art. L. 6143-7), établissement support d'un GHT, ou responsables conjoints (RGPD, art. 26). DPO associé dès la conception (art. 25, 38). Sous-traitant : hébergeur certifié HDS (art. 28).
Finalité, base légale	Pilotage de l'activité, de la qualité et de la performance ; indicateurs agrégés ; pas de recherche. Art. 6.1.e et 9.2.h RGPD.
Formalités	Registre (art. 30) ; AIPD obligatoire (données de santé à grande échelle, art. 35.3.b). Conformité au référentiel CNIL des entrepôts de données de santé : déclaration de conformité envisagée.
Information, sources	Art. 13, 14 et 21 (livret d'accueil, affichage, opposition). S2 : noms publics, minimisés ; S3 : agrégats ; S4 : RGPD inapplicable aux défunts (considérant 27), noms écartés.

SecNumCloud si l'AIPD le demande. **La VM du bloc ne reçoit que des données de test** : elle n'est pas un hébergement de santé.

5.2 Pseudonymisation, anonymisation et zones de sécurité

Classification. C3 directement identifiant (Bronze S1 et séjours) : zone Z2, aucun accès humain nominatif. **C2** pseudonymisé (Silver, lignes Gold) : Z3, accès nominatif habilité et journalisé. **C1** agrégats sous secret statistique (vues `v_ind_*`) : Z4, RLS par profil. **C0** public (S2 hors noms, S3, S4 sans noms, COG, CIM-10) : intégrité et traçabilité.

Pseudonymisation. HMAC-SHA-256 avec clé de 256 bits, variable *Password* lue par `tContextLoad` dans un fichier protégé. Pas de table de correspondance ; pseudonyme déterministe (suivi longitudinal) ; une clé par domaine ; rotation annuelle par recalcul complet.

Anonymisation des agrégats (secret statistique). Dans les vues `v_ind_*`, toute cellule de moins de **11 patients distincts** est masquée, seuil évalué après les filtres de lignes, avec masquage secondaire contre le calcul par différence (dans l'esprit du k-anonymat avec $k = 11$). Aucun identifiant ni pseudonyme n'est exposé dans les vues. Les résultats HAS, publics, ne sont pas concernés.

5.3 Rôles et droits d'accès, traçabilité des flux

Principes : moindre privilège, séparation des tâches, rôles par groupes de l'annuaire, recertification semestrielle. Trois niveaux de contrôle : (1) droits HDFS par couche ; (2) rôles Sentry, profils BI limités aux vues `v_ind_*` ; (3) sécurité au niveau des lignes de Power BI (RLS).

Traçabilité des flux. Flux : `ops.lot`, `ops.journal`, `ops.stat` (`tLogCatcher`, `tStatCatcher`, `tFlowMeterCatcher`), conservés 1 an. Lignage documenté (tableau 4.2) et porté par les données (`id_lot`, `_fichier_source`, `_ligne_source`). Accès : journaux HiveServer2, audit HDFS, journal Power BI, 1 an au SIEM, revue mensuelle par le RSSI.

5.4 Conservation, droits et incidents

Conservation : détail pseudonymisé Silver et Gold **10 ans glissants** ; agrégats anonymes sans limite après tests ; Bronze C3, rejets, répertoires de chargement : trois derniers chargements. **Droits** (art. 12 à 21 RGPD) : information patient ; accès et rectification sur le dossier source ; opposition et effacement par liste tenue en zone identifiante, appliquée au chargement suivant. **Incidents** :

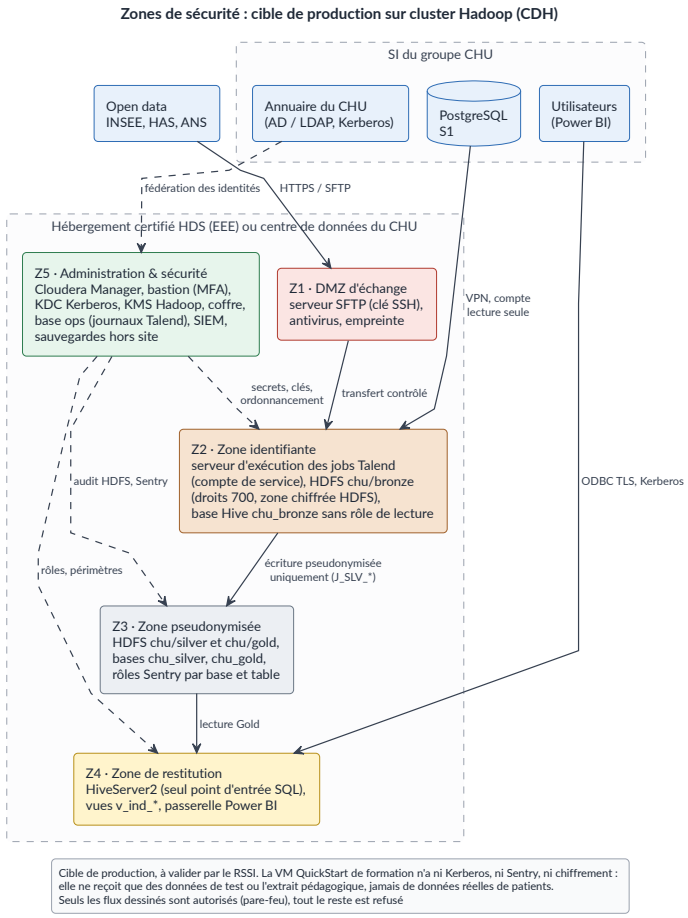


Figure 5.1 : Zones de sécurité et flux autorisés (cible de production)

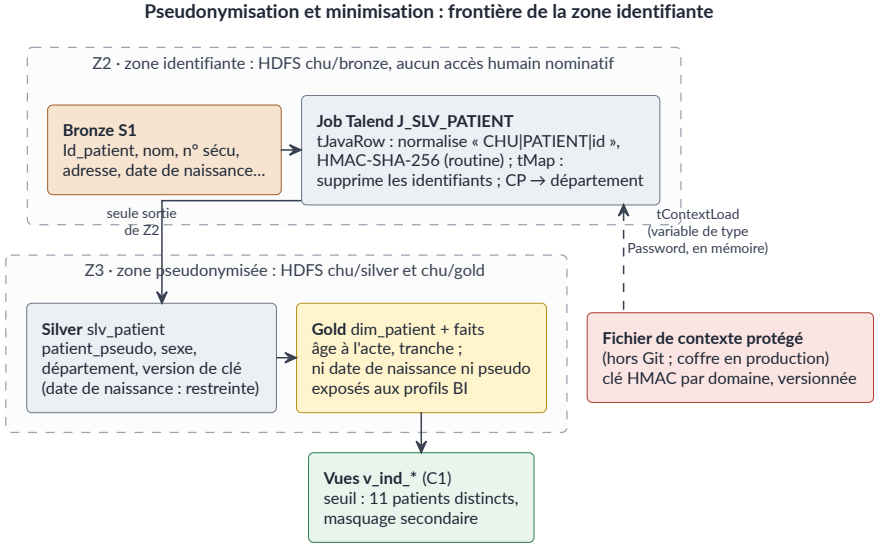


Figure 5.2 : Chaîne de pseudonymisation (séparation de la clé et frontière de la zone identifiante)

violation notifiée à la CNIL sous 72 h (art. 33), aux personnes si risque élevé (art. 34), à l'ARS et au CERT Santé.

Table 5.2 : Matrice RBAC (rôles × ressources)

Rôle	*Bronze (C3)*	*Silver (C2)*	*Gold lignes (C2)*	*Vues agrégées (C1)*	*Rejets*	*Journaux*	*Export / SQL*
Direction du groupe				L			
Direction d'établissement				$F_{établ}$			
Praticien, chef de service				F_{prof}			
Analyste, DIM			L^{J}	L			oui^{J}
Data steward		L^{J}		L	L/E		
Data engineer		L^{T}	L^{T}	L	L		
DPO, RSSI				L		L	
Jobs Talend (compte de service)	E/L	L/E	L/E	L/E	E		
Power BI → HiveServer2				L			
Administrateur plateforme						L	

Case vide : aucun accès ; L lecture ; E écriture ; F lecture filtrée par ligne ($_{établ}$ établissements de son périmètre, $_{prof}$ sa propre activité) ; ^{J} nominatif, journalisé, sur demande justifiée ; ^{T} temporaire, pour un incident.

A Dictionnaire de données

Pour chaque table : grain, historisation, alimentation, volumétrie, puis attributs avec type logique, nullabilité (NN non nul, N nul autorisé), rôle de clé (PK, FK → table, UK unicité) et règle de dérivation. Les types sont logiques ; leur traduction en types Hive est donnée au § 3.2 (`TIME` devient une chaîne `HH:mm:ss`, `CHAR(n)` un `VARCHAR(n)`) ; clés et non-nullité ne sont pas imposées par Hive et sont contrôlées avant publication (RQ-08, RQ-20, RQ-21). Les colonnes présentes dans plusieurs tables sont décrites une seule fois (tableau A.1). Le dictionnaire, les schémas en étoile et le DDL HiveQL sont produits à partir d'une même description du modèle : ils ne peuvent pas diverger.

Les cardinalités des clés étrangères sont données au tableau 2.3.

Table A.1 : Colonnes communes

Colonne	Type logique	Null	Présence et règle
`id_lot`	`VARCHAR(36)`	NN	Faits et dimensions non statiques. Identifiant (UUID) du lot de chargement ayant créé/modifié la ligne.
`dt_chargement`	`TIMESTAMP`	NN	Faits et dimensions non statiques. Horodatage technique d'insertion/mise à jour dans Gold.
`date_debut_validite`	`DATE`	NN	SCD 2 (`dim_etablissement`, `dim_professionnel`). Date d'effet de la version ; 1900-01-01 pour la première version.
`date_fin_validite`	`DATE`	NN	SCD 2 (`dim_etablissement`, `dim_professionnel`). Fin d'effet (9999-12-31 pour la version courante).
`est_version_courante`	`BOOLEAN`	NN	SCD 2 (`dim_etablissement`, `dim_professionnel`). Vrai pour la seule version en vigueur.

Attribut	Type logique	Null	Clé	Description, référence (→) et règle de dérivation
`fait_consultation` : Fait Consultation (transactionnel)				
Grain : une consultation (Num_consultation). **SCD** : aucune. **Job** : `J_FAIT_CONSULTATION`, mensuel. **Volume** : 1 027 157 (06/2015-03/2023). **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`consultation_id`	`BIGINT`	NN	PK	Dimension dégénérée : Num_consultation
`date_consultation_sk`	`INTEGER`	NN	FK	→ `dim_date`. Consultation.Date
`patient_sk`	`BIGINT`	NN	FK	→ `dim_patient`. Via Id_patient → patient_pseudo
`professionnel_sk`	`INTEGER`	NN	FK	→ `dim_professionnel`. Id_prof_sante
`etablissement_sk`	`INTEGER`	NN	FK	→ `dim_etablissement`. Organisation d'exercice du professionnel, version en vigueur à la date de l'acte
`geographie_etablissement_sk`	`INTEGER`	NN	FK	→ `dim_geographie`. Rôle « lieu de l'établissement » : code_commune de la version d'établissement retenue → dim_geographie
`diagnostic_sk`	`INTEGER`	NN	FK	→ `dim_diagnostic`. Code_diag
`mutuelle_sk`	`SMALLINT`	NN	FK	→ `dim_mutuelle`. Id_mut de la consultation
`acte_sk`	`SMALLINT`	NN	FK	→ `dim_acte`. Motif × plage horaire
`sexe_sk`	`SMALLINT`	NN	FK	→ `dim_sexe`. Patient.Sexe transcodé
`tranche_age_sk`	`SMALLINT`	NN	FK	→ `dim_tranche_age`. Âge révolu à la date de l'acte
`age_patient`	`SMALLINT`	N		Âge révolu à la date de l'acte, recalculé depuis la date de naissance
`duree_plage_minutes`	`SMALLINT`	N		Heure_fin - Heure_debut
`nb_consultation`	`SMALLINT`	NN		Mesure additive = 1

Attribut	Type logique	Null	Clé	Description, référence (→) et règle de dérivation
`fait_hospitalisation` : Fait Hospitalisation (séjour)				
Grain : un séjour hospitalier (Num_Hospitalisation). **SCD** : Rechargement complet à chaque livraison. **Job** : `J_FAIT_HOSPITALISATION`, mensuel. **Volume** : 2 479 (06/2015-06/2021). **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`sejour_id`	`BIGINT`	NN	PK	Dimension dégénérée : Num_Hospitalisation
`date_entree_sk`	`INTEGER`	NN	FK	→ `dim_date`. Date_Entree (JJ/MM/AAAA)
`date_sortie_sk`	`INTEGER`	NN	FK	→ `dim_date`. Date_Entree + Jour_Hospitalisation
`patient_sk`	`BIGINT`	NN	FK	→ `dim_patient`. Id_patient
`etablissement_sk`	`INTEGER`	NN	FK	→ `dim_etablissement`. identifiant_organisation
`geographie_etablissement_sk`	`INTEGER`	NN	FK	→ `dim_geographie`. Rôle « lieu de l'établissement » : code_commune de la version d'établissement retenue → dim_geographie
`diagnostic_sk`	`INTEGER`	NN	FK	→ `dim_diagnostic`. Code_diagnostic
`sexe_sk`	`SMALLINT`	NN	FK	→ `dim_sexe`. Sexe du patient
`tranche_age_sk`	`SMALLINT`	NN	FK	→ `dim_tranche_age`. Tranche d'âge à l'entrée
`age_entree`	`SMALLINT`	N		Âge révolu à l'entrée
`duree_sejour_jours`	`SMALLINT`	NN		Jour_Hospitalisation
`nb_sejour`	`SMALLINT`	NN		Mesure additive = 1
`fait_deces` : Fait Décès (open data INSEE)				
Grain : un acte de décès (après dédoublonnage). **SCD** : Ajout mensuel. **Job** : `J_FAIT_DECES`, mensuel. **Volume** : ≈ 25,1·10^6 (décès depuis 1970 ; échantillon : 1983). **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`deces_id`	`CHAR(64)`	NN	PK	SHA-256(numero_acte_deces | code_lieu_deces | date_deces) : clé de dédoublonnage
`date_deces_sk`	`INTEGER`	NN	FK	→ `dim_date`. date_deces ; -1 si partielle ou invalide
`geographie_deces_sk`	`INTEGER`	NN	FK	→ `dim_geographie`. code_lieu_deces → commune COG courante
`sexe_sk`	`SMALLINT`	NN	FK	→ `dim_sexe`. sexe (1/2)
`tranche_age_sk`	`SMALLINT`	NN	FK	→ `dim_tranche_age`. Tranche de l'âge au décès
`annee_deces`	`SMALLINT`	N		Année de décès, conservée même si la date est partielle
`age_deces`	`SMALLINT`	N		Âge révolu au décès
`nb_deces`	`SMALLINT`	NN		Mesure additive = 1
`fait_indicateur_qualite` : Fait Indicateur qualité & satisfaction (instantané périodique)				
Grain : un résultat d'indicateur pour un établissement et une campagne ; unicité aussi testée sur (identifiant_organisation, campagne, indicateur). **SCD** : Ajout par campagne. **Job** : `J_FAIT_INDICATEUR_QUALITE`, mensuel. **Volume** : ≈ 10^5 (format long). **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`etablissement_sk`	`INTEGER`	NN	PK, FK	→ `dim_etablissement`. finess_geo (à défaut finess) → version en vigueur au 1er janvier de annee_donnees (date de référence fixe)
`campagne_sk`	`SMALLINT`	NN	PK, FK	→ `dim_campagne`. Millésime du fichier
`indicateur_sk`	`SMALLINT`	NN	PK, FK	→ `dim_indicateur`. Indicateur canonique
`date_reference_sk`	`INTEGER`	NN	FK	→ `dim_date`. 1er janvier de dim_campagne.annee_donnees
`geographie_etablissement_sk`	`INTEGER`	NN	FK	→ `dim_geographie`. Rôle « lieu de l'établissement » : code_commune de la version d'établissement retenue → dim_geographie
`valeur`	`DECIMAL(9,4)`	N		Score / taux (virgule ou point décimal normalisés)
`effectif_base`	`INTEGER`	N		Effectif de base
`ic_bas`	`DECIMAL(9,4)`	N		Borne basse de l'intervalle de confiance
`ic_haut`	`DECIMAL(9,4)`	N		Borne haute (*_ichaut_etbt)

Attribut	Type logique	Null	Clé	Description, référence (→) et règle de dérivation
classe	VARCHAR(4)	N		A, B, C, D, DI, NR, NV
evolution	VARCHAR(30)	N		Évolution de classe déclarée par la HAS
est_participation_obligatoire	BOOLEAN	N		participation = « 1- Obligatoire »
est_diffusable	BOOLEAN	NN		Faux si classe DI/NR/NV ou valeur absente
dim_date : Dimension Temps (calendrier)				
Grain : un jour calendaire. **SCD** : Statique (générée). **Job** : J_DIM_DATE, mensuel. **Volume** : ≈ 24 100 (1970-2035).				
date_sk	INTEGER	NN	PK	Clé « intelligente » AAAAMMJJ
date_complete	DATE	N	UK	Date calendaire
annee	SMALLINT	N		Année civile
semestre	SMALLINT	N		1 ou 2
trimestre	SMALLINT	N		1 à 4
mois	SMALLINT	N		1 à 12
libelle_mois	VARCHAR(12)	N		Libellé français
annee_mois	CHAR(7)	N		Clé de regroupement AAAA-MM
semaine_iso	SMALLINT	N		Numéro de semaine ISO 8601
annee_iso	SMALLINT	N		Année ISO 8601 de la semaine
semaine_epidemio	INTEGER	N		Semaine épidémiologique au format AAAASS
jour_mois	SMALLINT	N		1 à 31
jour_semaine_iso	SMALLINT	N		1 = lundi … 7 = dimanche
libelle_jour	VARCHAR(10)	N		Libellé français du jour
est_week_end	BOOLEAN	NN		Samedi ou dimanche
est_jour_ferie	BOOLEAN	NN		Jour férié légal
est_jour_ouvre	BOOLEAN	NN		Lundi à vendredi hors jour férié
dim_patient : Dimension Patient pseudonymisé				
Grain : un patient (Id_patient source). **SCD** : Type 1. **Job** : J_DIM_PATIENT, mensuel. **Volume** : 100 000. **Colonnes communes** : id_lot, dt_chargement (tableau A.1).				
patient_sk	BIGINT	NN	PK	Clé de substitution
patient_pseudo	CHAR(64)	NN	UK	HMAC-SHA-256(clé KMS, « CHU|PATIENT|<Id_patient> ») en hexadécimal
code_departement_residence	VARCHAR(3)	N		Généralisation de Code_postal
code_region_residence	CHAR(2)	N		Région COG déduite du département
dim_sexe : Dimension Sexe (conforme)				
Grain : une modalité de sexe. **SCD** : Statique. **Job** : J_DIM_SEXE, mensuel. **Volume** : 3.				
sexe_sk	SMALLINT	NN	PK	Clé ; -1 = inconnu
sexe_code	CHAR(1)	NN	UK	Code INSEE : 1 = masculin, 2 = féminin, 9 = inconnu
sexe_libelle	VARCHAR(20)	NN		Masculin, Féminin, Inconnu
dim_tranche_age : Dimension Tranche d'âge (conforme)				
Grain : une tranche quinquennale d'âge révolu. **SCD** : Statique. **Job** : J_DIM_TRANCHE_AGE, mensuel. **Volume** : 21.				
tranche_age_sk	SMALLINT	NN	PK	Clé ; -1 = âge inconnu ou incohérent
age_min	SMALLINT	N		Borne inférieure incluse
age_max	SMALLINT	N		Borne supérieure incluse
libelle_tranche	VARCHAR(16)	NN	UK	Ex. « 00-04 ans »
classe_age	VARCHAR(20)	NN		0-17, 18-64, 65 ans et +
ordre_tri	SMALLINT	NN		Ordre d'affichage

Attribut	Type logique	Null	Clé	Description, référence (→) et règle de dérivation
`dim_geographie` : Dimension Géographie (COG INSEE)				
Grain : une commune du COG courant, ou un pays pour l'étranger. **SCD** : Type 1 (re-projection sur le COG courant). **Job** : `J_DIM_GEOGRAPHIE`, mensuel. **Volume** : ≈ 35 000. **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`geographie_sk`	`INTEGER`	NN	PK	Clé ; -1 = lieu inconnu, -3 = code absent du COG après reprojection
`code_commune`	`CHAR(5)`	NN	UK	Code commune COG, ou 99CCC
`libelle_commune`	`VARCHAR(100)`	NN		Libellé officiel
`code_departement`	`VARCHAR(3)`	N		Code département
`libelle_departement`	`VARCHAR(60)`	N		Libellé département
`code_region`	`CHAR(2)`	NN		Code région COG
`libelle_region`	`VARCHAR(60)`	NN		Libellé officiel de la région
`est_etranger`	`BOOLEAN`	NN		Vrai si code 99CCC
`millesime_cog`	`SMALLINT`	NN		Millésime COG de référence
`dim_etablissement` : Dimension Établissement / organisation				
Grain : une version d'une organisation de l'annuaire santé (FINESS géographique ou cabinet SIRET). **SCD** : Type 2 (raison sociale, commune, entité juridique, catégorie). **Job** : `J_DIM_ETABLISSEMENT`, mensuel. **Volume** : ≈ 416 700 organisations. **Colonnes communes** : triplet SCD 2 ; `id_lot`, `dt_chargement` (tableau A.1).				
`etablissement_sk`	`INTEGER`	NN	PK	Clé (une par version)
`identifiant_organisation`	`VARCHAR(20)`	NN		Clé naturelle et clé durable, stable entre versions
`type_organisation`	`CHAR(1)`	NN		F = établissement FINESS
`finess_geographique`	`CHAR(9)`	N		identifiant_organisation sans le préfixe F
`finess_juridique`	`CHAR(9)`	N		finess_etablissement_juridique
`siret`	`CHAR(14)`	N		siret_site
`raison_sociale`	`VARCHAR(150)`	NN		raison_sociale_site
`categorie_libelle`	`VARCHAR(100)`	N		Catégorie d'établissement
`code_postal`	`CHAR(5)`	N		code_postal
`code_commune`	`CHAR(5)`	N		code_commune (COG)
`libelle_commune`	`VARCHAR(100)`	N		Attribut conforme issu de dim_geographie
`code_departement`	`VARCHAR(3)`	N		Attribut conforme issu de dim_geographie
`code_region`	`CHAR(2)`	N		Attribut conforme issu de dim_geographie
`libelle_region`	`VARCHAR(60)`	N		Attribut conforme issu de dim_geographie
`est_groupe_chu`	`BOOLEAN`	NN		Vrai si l'organisation appartient au périmètre du groupe CHU
`dim_diagnostic` : Dimension Diagnostic (CIM-10)				
Grain : un code diagnostic. **SCD** : Type 1. **Job** : `J_DIM_DIAGNOSTIC`, mensuel. **Volume** : 15 490. **Colonnes communes** : `id_lot`, `dt_chargement` (tableau A.1).				
`diagnostic_sk`	`INTEGER`	NN	PK	Clé ; -1 = non renseigné, -3 = code hors référentiel
`code_diag`	`VARCHAR(6)`	NN	UK	Code_diag (3 à 6 caractères, extensions CIM-10 FR)
`libelle_diagnostic`	`VARCHAR(255)`	NN		Diagnostic
`code_categorie`	`CHAR(3)`	NN		3 premiers caractères
`code_chapitre`	`VARCHAR(5)`	N		Chapitre CIM-10
`libelle_chapitre`	`VARCHAR(255)`	N		Libellé du chapitre
`dim_professionnel` : Dimension Professionnel de santé				
Grain : une version d'un professionnel. **SCD** : Type 2 (profession, spécialité, mode d'exercice). **Job** : `J_DIM_PROFESSIONNEL`, mensuel. **Volume** : ≈ 1,05·10^6 (fichier plafonné à la limite d'Excel). **Colonnes communes** : triplet SCD 2 ; `id_lot`, `dt_chargement` (tableau A.1).				
`professionnel_sk`	`INTEGER`	NN	PK	Clé (une par version)
`professionnel_pseudo`	`CHAR(64)`	NN		HMAC-SHA-256 de l'identifiant normalisé
`type_identifiant`	`VARCHAR(5)`	NN		RPPS ou ADELI

Attribut	Type logique	Null	Clé	Description, référence (→) et règle de dérivation
profession	VARCHAR(60)	N		Profession (Médecin, Infirmier…)
categorie_professionnelle	VARCHAR(20)	N		Civil, Militaire, Étudiant
specialite_code	VARCHAR(10)	N		Code_specialite
specialite_libelle	VARCHAR(100)	N		Specialites.Specialite
fonction	VARCHAR(60)	N		Specialites.Fonction
mode_exercice	VARCHAR(20)	N		Libéral / Salarié
dim_mutuelle : Dimension Mutuelle (organisme complémentaire)				
Grain : un organisme complémentaire. **SCD** : Type 1. **Job** : J_DIM_MUTUELLE, mensuel. **Volume** : 254. **Colonnes communes** : id_lot, dt_chargement (tableau A.1).				
mutuelle_sk	SMALLINT	NN	PK	Clé ; -1 = inconnue
id_mutuelle	INTEGER	NN	UK	Id_Mut source
nom_mutuelle	VARCHAR(150)	NN		Nom
dim_acte : Dimension Acte de consultation (junk)				
Grain : une combinaison motif × plage horaire. **SCD** : Statique (alimentée par les valeurs observées). **Job** : J_DIM_ACTE, mensuel. **Volume** : ≈ 100.				
acte_sk	SMALLINT	NN	PK	Clé ; -1 = inconnu
motif	VARCHAR(60)	NN		Motif source (ex
famille_motif	VARCHAR(30)	NN		Regroupement : Consultation, Dentaire, Imagerie, Biologie, Soins
plage_horaire	VARCHAR(12)	NN		MATIN (08-12), APRES_MIDI (13-18), SOIR (20-23), NUIT (20-02)
heure_debut	TIME	NN		Heure_debut de la plage
heure_fin	TIME	NN		Heure_fin de la plage
dim_campagne : Dimension Campagne de mesure (HAS)				
Grain : une campagne d'un dispositif de mesure (millésime de fichier). **SCD** : Statique (une ligne par fichier/millésime). **Job** : J_DIM_CAMPAGNE, mensuel. **Volume** : ≈ 25.				
campagne_sk	SMALLINT	NN	PK	Clé ; -1 = inconnue
dispositif	VARCHAR(40)	NN		e-Satis 48h MCO, e-Satis MCO CA, IQSS DPA SSR, IQSS RCP MCO…
annee_publication	SMALLINT	NN		Année de recueil / publication
annee_donnees	SMALLINT	N		Année des données
fichier_source	VARCHAR(120)	NN	UK	Nom du fichier source
dim_indicateur : Dimension Indicateur (canonique)				
Grain : un indicateur canonique, indépendant des noms de colonnes des millésimes. **SCD** : Type 1. **Job** : J_DIM_INDICATEUR, mensuel. **Volume** : ≈ 60.				
indicateur_sk	SMALLINT	NN	PK	Clé ; -1 = inconnu
code_indicateur	VARCHAR(40)	NN	UK	Ex. ESATIS48H_SCORE_GLOBAL, ESATISCA_SCORE_GLOBAL, ESATIS48H_SCORE_REPAS
libelle_indicateur	VARCHAR(200)	NN		Libellé issu des lexiques HAS
famille	VARCHAR(30)	NN		SATISFACTION, QUALITE_PRISE_EN_CHARGE, SECURITE…
secteur	VARCHAR(10)	NN		MCO, MCO-CA, SSR, HAD
unite	VARCHAR(20)	NN		Score /100, %, ratio O/A
sens_favorable	CHAR(1)	NN		« + » si une valeur élevée est favorable, « - » sinon