CESI

ÉCOLE D'INGÉNIEURS

Bloc Stockage et Big Data

PGE A4 FISA / A3 FISE Big Data, promotion 2026-2027

PROJET CLOUD HEALTHCARE UNIT

Livrable 2 : rapport écrit + archive ZIP

Implémentation physique et évaluation de performance

Auteurs Tony Fages, Martin Caparros, David d'Almeida

Date 30 octobre 2026

Table des matières

1 Architecture de la plateforme **2**

2 Modele physique : schema en etoile **2**
2.1 Schema en etoile . . . 2
2.2 Dictionnaire des tables . . . 3
2.3 Les 4 mesures de `f_mesures` . . . 3
2.4 Contraintes d'integrite referentielle . . . 3
2.5 Vues metier . . . 4

3 DDL et DML commentes **4**
3.1 DDL Hive – tables externes (extrait) . . . 4
3.2 DML – chargement par Apache Spark . . . 4
3.3 Volumes charges, verifies dans Trino . . . 5
3.4 Preuve de fonctionnement (captures) . . . 6

4 Strategie de partitionnement et d'indexation **11**
4.1 Partitionnement . . . 11
4.2 Indexation complementaire . . . 11

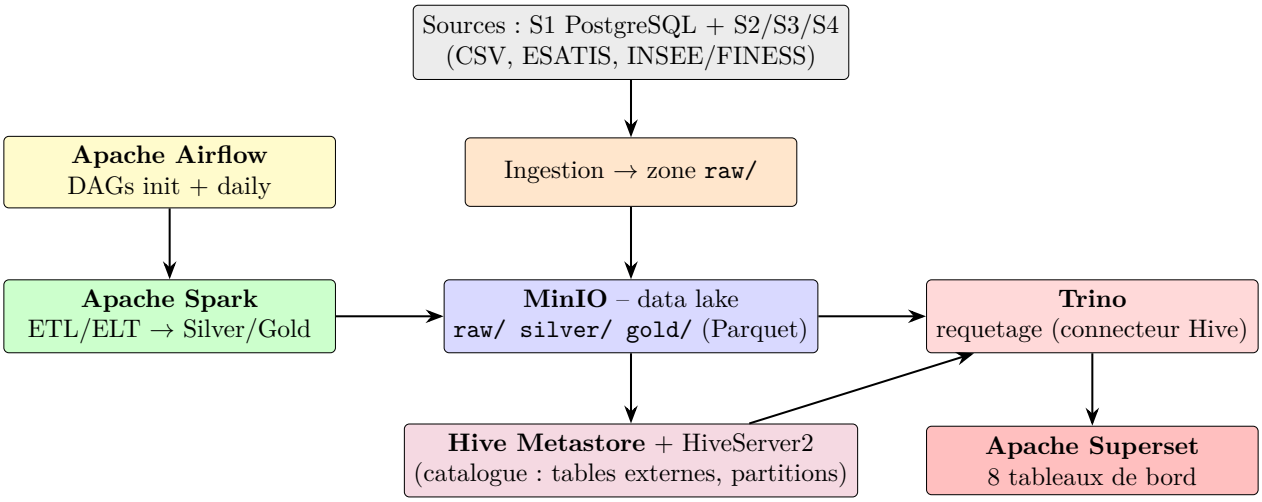
5 Rapport de qualite des donnees integrees **11**
5.1 Completude par attribut – sources . . . 12
5.2 Completude par attribut – faits integres (lake) . . . 12
5.3 Validite des formats . . . 13
5.4 Doublons – sources puis faits integres . . . 14
5.5 Coherence referentielle – codes FINESS . . . 14
5.6 Temporalité . . . 16
5.7 Traitements appliques (derives des controles) . . . 17

6 Jeu de requetes de benchmark **17**
6.1 Extraits de resultats metier . . . 18

7 Evaluation de performance – avant/apres partitionnement **19**
7.1 Protocole . . . 19
7.2 Resultats PoC (medianes) . . . 19
7.3 Resultats sur Trino deploye (harnais execute) . . . 22
7.4 Analyse et interpretation . . . 23

1 Architecture de la plateforme

Figure 1 – Architecture de bout en bout – 17 services conteneurises



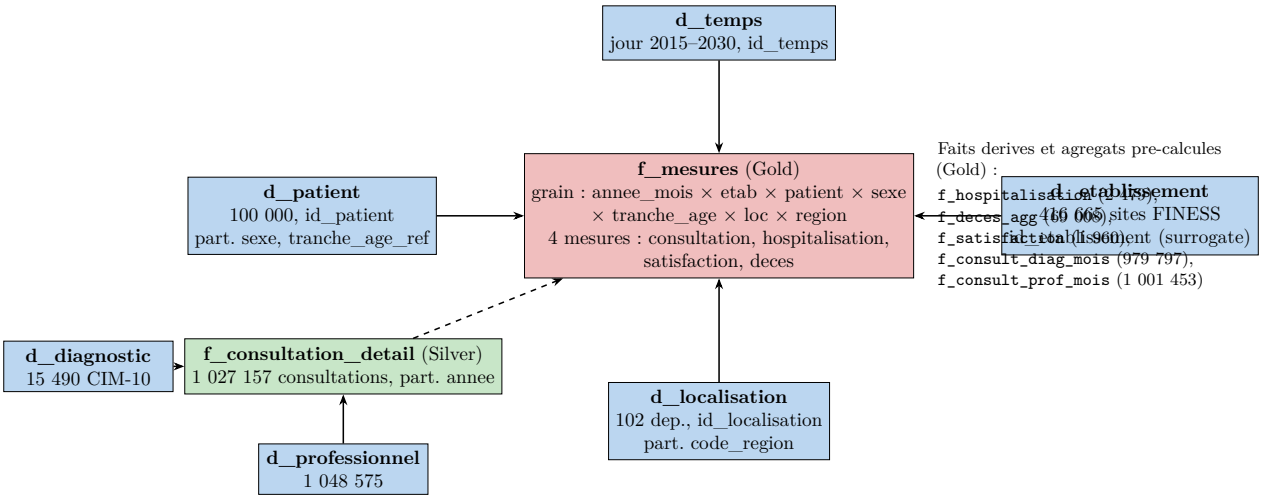
La chaine de production a ete executee de bout en bout : DAG d'initialisation (5/5 taches en succes) puis DAG journalier (8/8 taches en succes) ; les volumes ont ete re-verifies dans Trino (§3.3) et des captures d'ecran des interfaces de la plateforme sont presentees en §3.4.

2 Modele physique : schema en etoile

2.1 Schema en etoile

Le modele du Livrable 1 est implemente en couche **Gold** (decisionnel) sur le data lake, avec une couche **Silver** pour le fait de detail des consultations. **13 tables externes (12 Gold + 1 Silver)**, toutes en `CREATE EXTERNAL TABLE ... STORED AS PARQUET LOCATION 's3a://lake/...'` (les donnees appartiennent au lake ; un `DROP TABLE` ne supprime jamais les donnees). Les cles de substitution (surrogate keys) sont presentes dans les dimensions : `id_temps` (AAAAMMJJ), `id_patient`, `id_etablissement` (`row_number`), `id_localisation` (code departement), `id_diagnostic` (`row_number`), `identifiant` (professionnel).

Figure 2 – Schema en etoile deploye (couches Gold/Silver)



2.2 Dictionnaire des tables

Table 1 – Dictionnaire des 13 tables externes (6 dimensions, 5 faits, 2 agregats) – volumes mesures en lignes

Table (cle)	Grain, couche, partitionnement et tri	Lignes
`d_temps` (`id_temps`, AAAAMMJJ)	jour 2015–2030 ; Gold ; part. `annee`	5 844
`d_patient` (`id_patient`)	patient ; Gold ; part. `sexe`, `tranche_age_ref`	100 000
`d_etablissement` (`id_etablissement`, surrogate)	site FINESS ; Gold	416 665
`d_localisation` (`id_localisation`)	departement ; Gold ; part. `code_region`	102
`d_diagnostic` (`id_diagnostic`, surrogate)	diagnostic CIM-10 ; Gold	15 490
`d_professionnel` (`identifiant`)	professionnel ADELI ; Gold	1 048 575
`f_mesures` (fait)	annee_mois × etab × patient × sexe × tranche_age × dep. × region ; Gold ; part. `annee`, `sexe`, `tranche_age` ; tri `id_etablissement`, `id_patient`	**1 030 402**
`f_consultation_detail` (`id_consultation`)	consultation ; Silver ; part. `annee` ; tri `id_etablissement`, `id_patient`	1 027 157
`f_hospitalisation` (`id_hospitalisation`)	hospitalisation ; Gold ; part. `annee` ; tri `id_etablissement`, `id_patient`	2 479
`f_deces_agg` (fait agr.)	annee × sexe × tranche_age × departement ; Gold ; part. `annee`	69 008
`f_satisfaction` (fait)	finess juridique × annee ; Gold ; part. `annee`, `code_region`	1 960
`f_consult_diag_mois` (agr.)	mois × diagnostic × etab ; Gold ; part. `annee`	979 797
`f_consult_prof_mois` (agr.)	mois × professionnel ; Gold ; part. `annee`	1 001 453

2.3 Les 4 mesures de `f_mesures`

Table 2 – Mesures du fait consolide

Mesure	Definition	Grain dans `f_mesures`
`nbre_consultation`	nombre de consultations	mensuel (`annee_mois = 'AAAA-MM'`)
`nbre_hospitalisation`	nombre d'hospitalisations	mensuel
`total_satisfaction`	score moyen ajuste ESATIS (0–100), moyenne ponderee par les repondants, par region	annuel (sentinelle `'AAAA-00'`)
`nbre_deces`	nombre de deces	annuel (sentinelle `'AAAA-00'`)

Conventions : membres «Inconnu» (`id_etablissement = -1`, `id_patient = -1`, `id_localisation = 'INCONNU'`, `region = 'INCONNUE'`, `sexe = 'TOUS'`, `tranche_age = 'TOUTES'`) pour les lignes non rattachables ; sentinelle `annee_mois = 'AAAA-00'` pour les mesures de grain annuel.

2.4 Contraintes d'integrite referentielle

Le moteur retenu (tables externes Hive/Parquet sur MinIO) ne supporte pas les constraints `FOREIGN KEY` declaratives. L'integrite referentielle est donc **assuree par construction** – les faits ne contiennent que des cles produites par les dimensions, dans l'ordre d'execution des DAGs (dimensions d'abord, faits ensuite, mesures calculees *apres* le peuplement des cles etrangeres) – et **controlee a posteriori** par les controles qualite «integrite faits → dimensions» (§5.5) : 13 controles, taux de rattachement mesures, aucun rejet silencieux.

2.5 Vues metier

Les vues metier Hive (les 4 faits metier du Livrable 1 derives de `f_mesures`, le taux de consultation mensuel avec moyenne mobile 3 mois – fonction fenetree –, et 4 vues d'agregat) sont recreees en vues natives Trino (schema `vues_t`), le connecteur Hive de Trino ne lisant pas les vues Hive ; c'est ce schema que Superset et les requetes de benchmark interrogent.

3 DDL et DML commentes

3.1 DDL Hive – tables externes (extrait)

Le DDL Hive cree les schemas `silver` et `gold` et les 13 tables externes, commentees ligne par ligne. Extraits representatifs :

```
-- Fait consolide : partitionnement demographique + temporel
CREATE EXTERNAL TABLE IF NOT EXISTS gold.f_mesures (
  annee_mois STRING, id_temps INT, id_etablissement BIGINT,
  id_patient BIGINT, id_localisation STRING,
  nbre_consultation BIGINT, nbre_hospitalisation BIGINT,
  total_satisfaction DOUBLE, nbre_deces BIGINT, region STRING
)
PARTITIONED BY (annee INT, sexe STRING, tranche_age STRING)
STORED AS PARQUET
LOCATION 's3a://lake/gold/f_mesures';

-- Dimension localisation : partitionnee par code_region (les noms de
-- regions contiennent espaces/accents/apostrophe, caracteres invalides
-- dans les repertoires de partitions Hive)
CREATE EXTERNAL TABLE IF NOT EXISTS gold.d_localisation (
  id_localisation STRING, code_departement STRING,
  nom_departement STRING, region STRING
)
PARTITIONED BY (code_region STRING)
STORED AS PARQUET
LOCATION 's3a://lake/gold/d_localisation';
```

Cote Trino, aucun DDL duplique : le connecteur `hive` lit le Hive Metastore ; un script de verification controle les volumes, calcule les statistiques de l'optimiseur (`ANALYZE`) et valide le pruning (`EXPLAIN (TYPE IO)`).

3.2 DML – chargement par Apache Spark

Le chargement est ecrit en PySpark, moteur de traitement impose par la stack, ciblant des tables externes Hive/Parquet sur le lake. Les memes regles de transformation sont exprimees en DML SQL (`INSERT`) dans le scenario de benchmark. Les jobs et leurs regles (issues des controles qualite, §5) :

Table 3 – Jobs de chargement et regles de transformation

Job	Role	Regles de transformation
Session Spark et fonctions communes	session S3A/MinIO + Metastore, helpers	`tranche_age` (0-14/15-29/30-44/45-59/60-74/75+), `dept_of` (regle INSEE, Corse 2A), sexe normalise M/F, age revolu
Chargement des dimensions	6 dimensions	`d_patient` : sexe normalise, date parsee, tranche a la ref. 2023-12-31 ; `d_etablissement` : surrogate `row_number`, rattachement commune → departement → region ; `d_localisation` : 101 dep. + Inconnu
Chargement des faits de detail	`f_consultation_detail` (Silver), `f_hospitalisation`, `f_satisfaction`	rattachement etablissement via le fichier d'activite ; ESATIS : virgule decimale remplacee ; region normalisee (mapping 18 regions) ; grain satisfaction = finess juridique × annee
Aggregation des deces	`f_deces_agg` (25,09 M deces INSEE)	filtre des 646 dates invalides, agregat annuel (annee × sexe × tranche_age × departement)
Construction du fait consolide	`f_mesures`	aggregation des 4 sources au grain commun, **calcul des mesures APRES peuplement des cles etrangeres**, sentinelle `'AAAA-00'`, region denormalisee
Agregats pre-calcules	`f_consult_diag_mois`, `f_consult_prof_mois`	agregats pre-calcules (besoins 2 et 6)

Chaque ecriture Spark : `partitionBy(...).sortWithinPartitions(id_etablissement, id_patient) ... saveAsTable(...)` → table externe Parquet partitionnee et triee ; metadonnees publiees dans le Hive Metastore ; partitions decouvertes (`MSCK REPAIR`) ; statistiques calculees (`ANALYZE` Trino apres chargement).

3.3 Volumes charges, verifies dans Trino

Apres decouverte des partitions, les volumes ont ete re-verifies **dans Trino** (connecteur Hive → MinIO), après l'execution du DAG d'initialisation (5/5 taches en succes) puis du DAG journalier (8/8 taches en succes) :

Table 4 – Volumes mesures dans Trino – dimensions

`d_temps`	5 844
`d_patient`	100 000
`d_etablissement`	416 665
`d_localisation`	102
`d_diagnostic`	15 490
`d_professionnel`	1 048 575

Table 5 – Volumes mesures dans Trino – faits et agregats

`f_consultation_detail` (Silver)	1 027 157
`f_hospitalisation`	2 479
`f_deces_agg`	69 008
`f_satisfaction`	1 960
`f_mesures`	**1 030 402**
`f_consult_diag_mois`	979 797
`f_consult_prof_mois`	1 001 453

Dans `f_mesures` : 1 027 157 consultations, 2 479 hospitalisations, 3 215 529 deces (2015–2023) ;

la satisfaction est stockee dans `f_satisfaction` au grain juridique (2 295 lignes source ESATIS agreeees en 1 960 finess juridiques, moyenne ponderee par les repondants) et `f_mesures` n'en agreee que 33 lignes regionales.

3.4 Preuve de fonctionnement (captures)

Captures d'ecran realisees sur la plateforme deployee (conteneurs Docker) :

Figure 3 – Airflow : DAGs `lakehouse_init` et `lakehouse_daily`, taches en succes (vert)

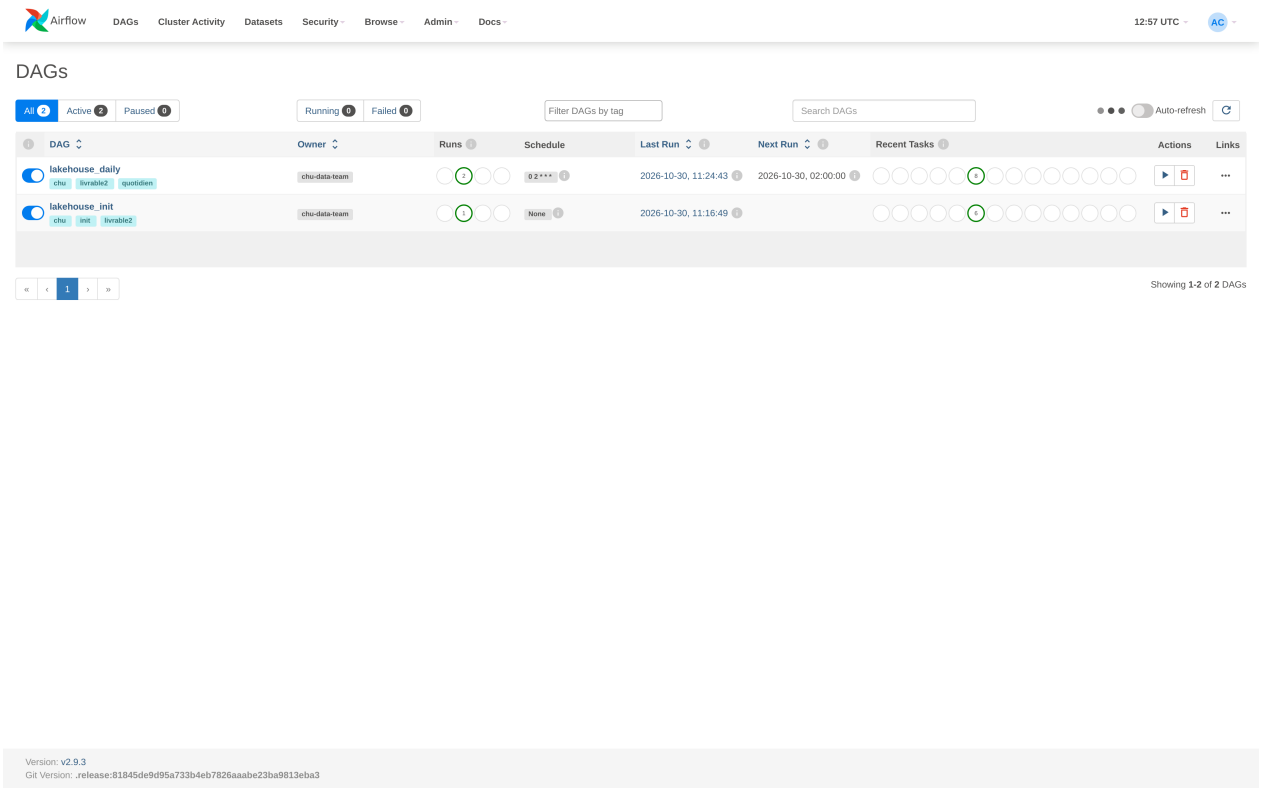


Figure 4 – Trino 484 (UI web) : tableau de bord du coordinateur – workers actifs et requetes recentes (etat, duree, SQL)

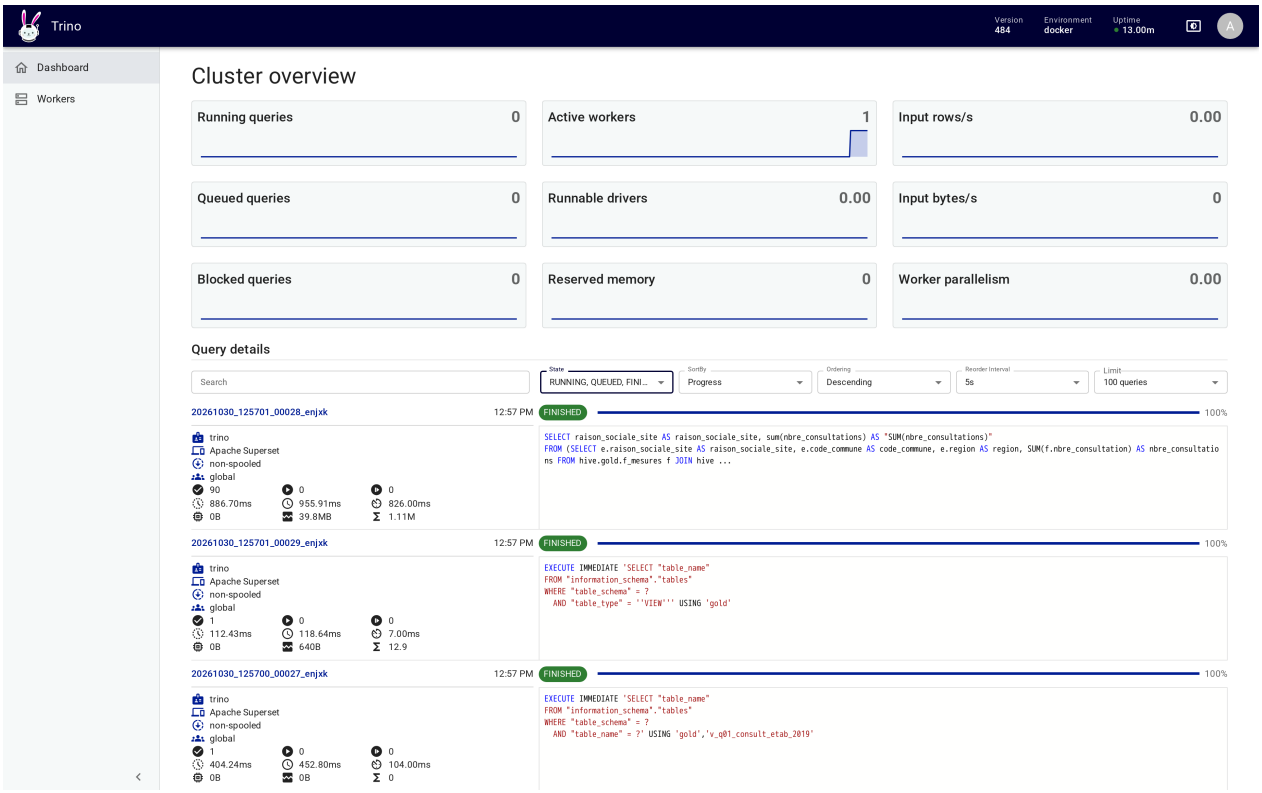


Figure 5 – MinIO (console) : liste des buckets, dont `lake`

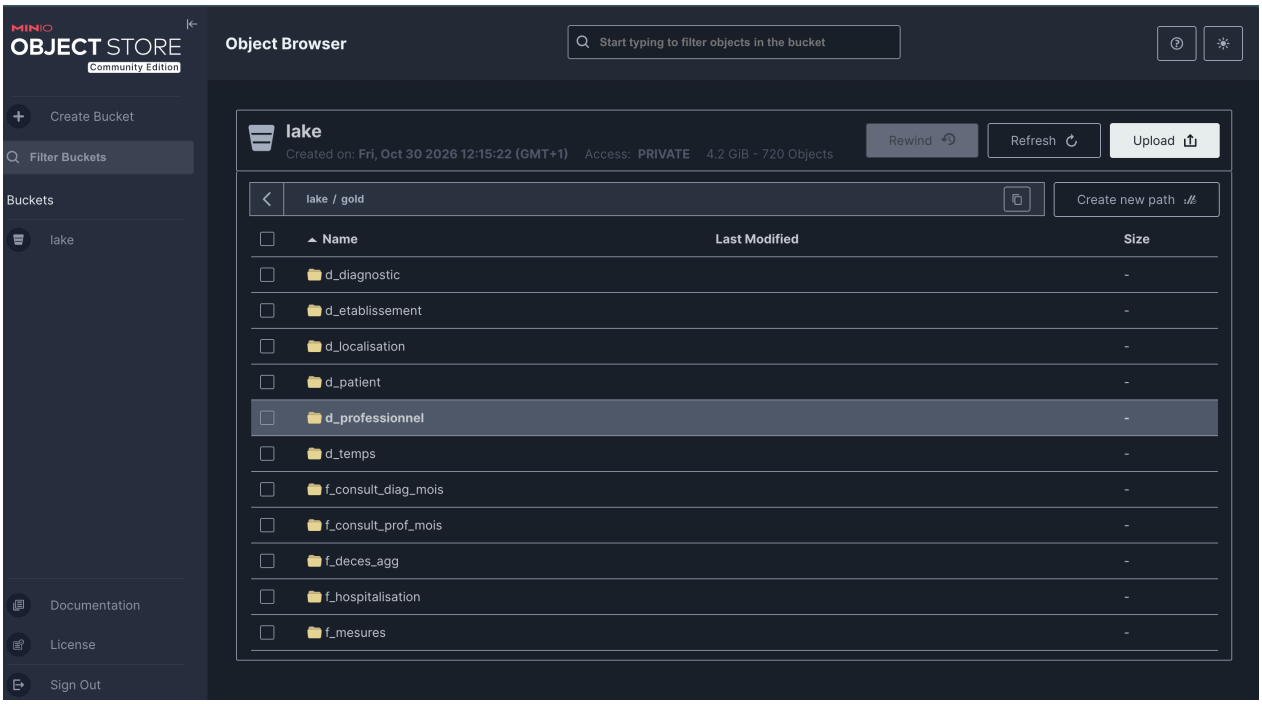


Figure 6 – MinIO (console) : contenu du bucket `lake` (zones raw/silver/gold)

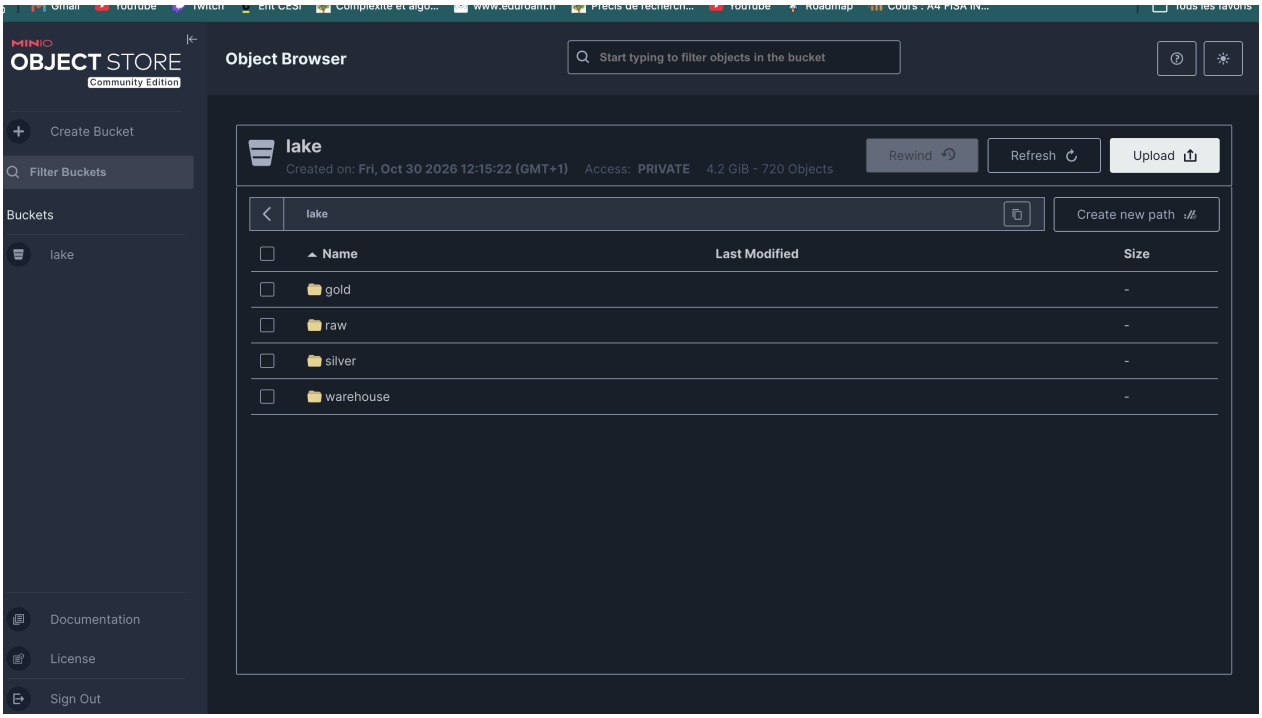


Figure 7 – Superset : tableau de bord «CHU – Indicateurs metier» publie (liste de ses graphiques)

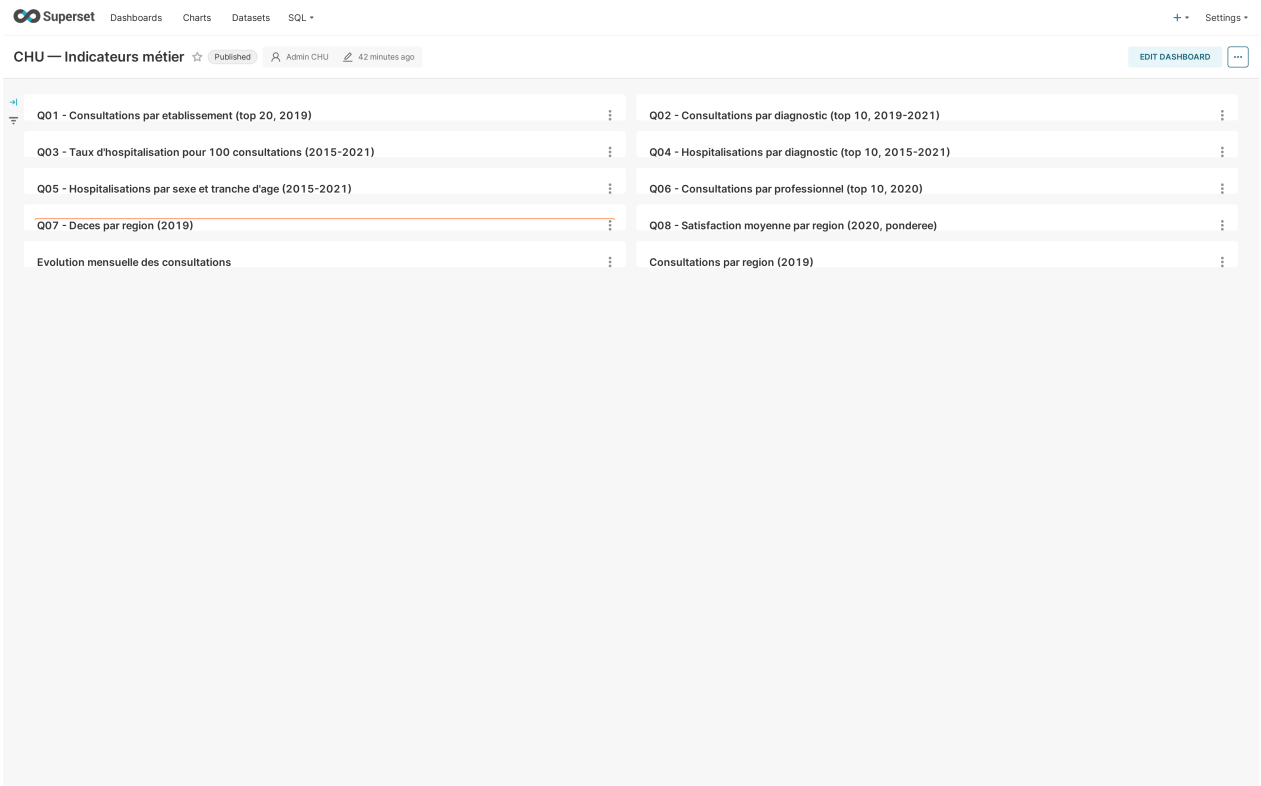


Figure 8 – Superset : tableau de bord «CHU – Indicateurs metier» avec graphiques rendus

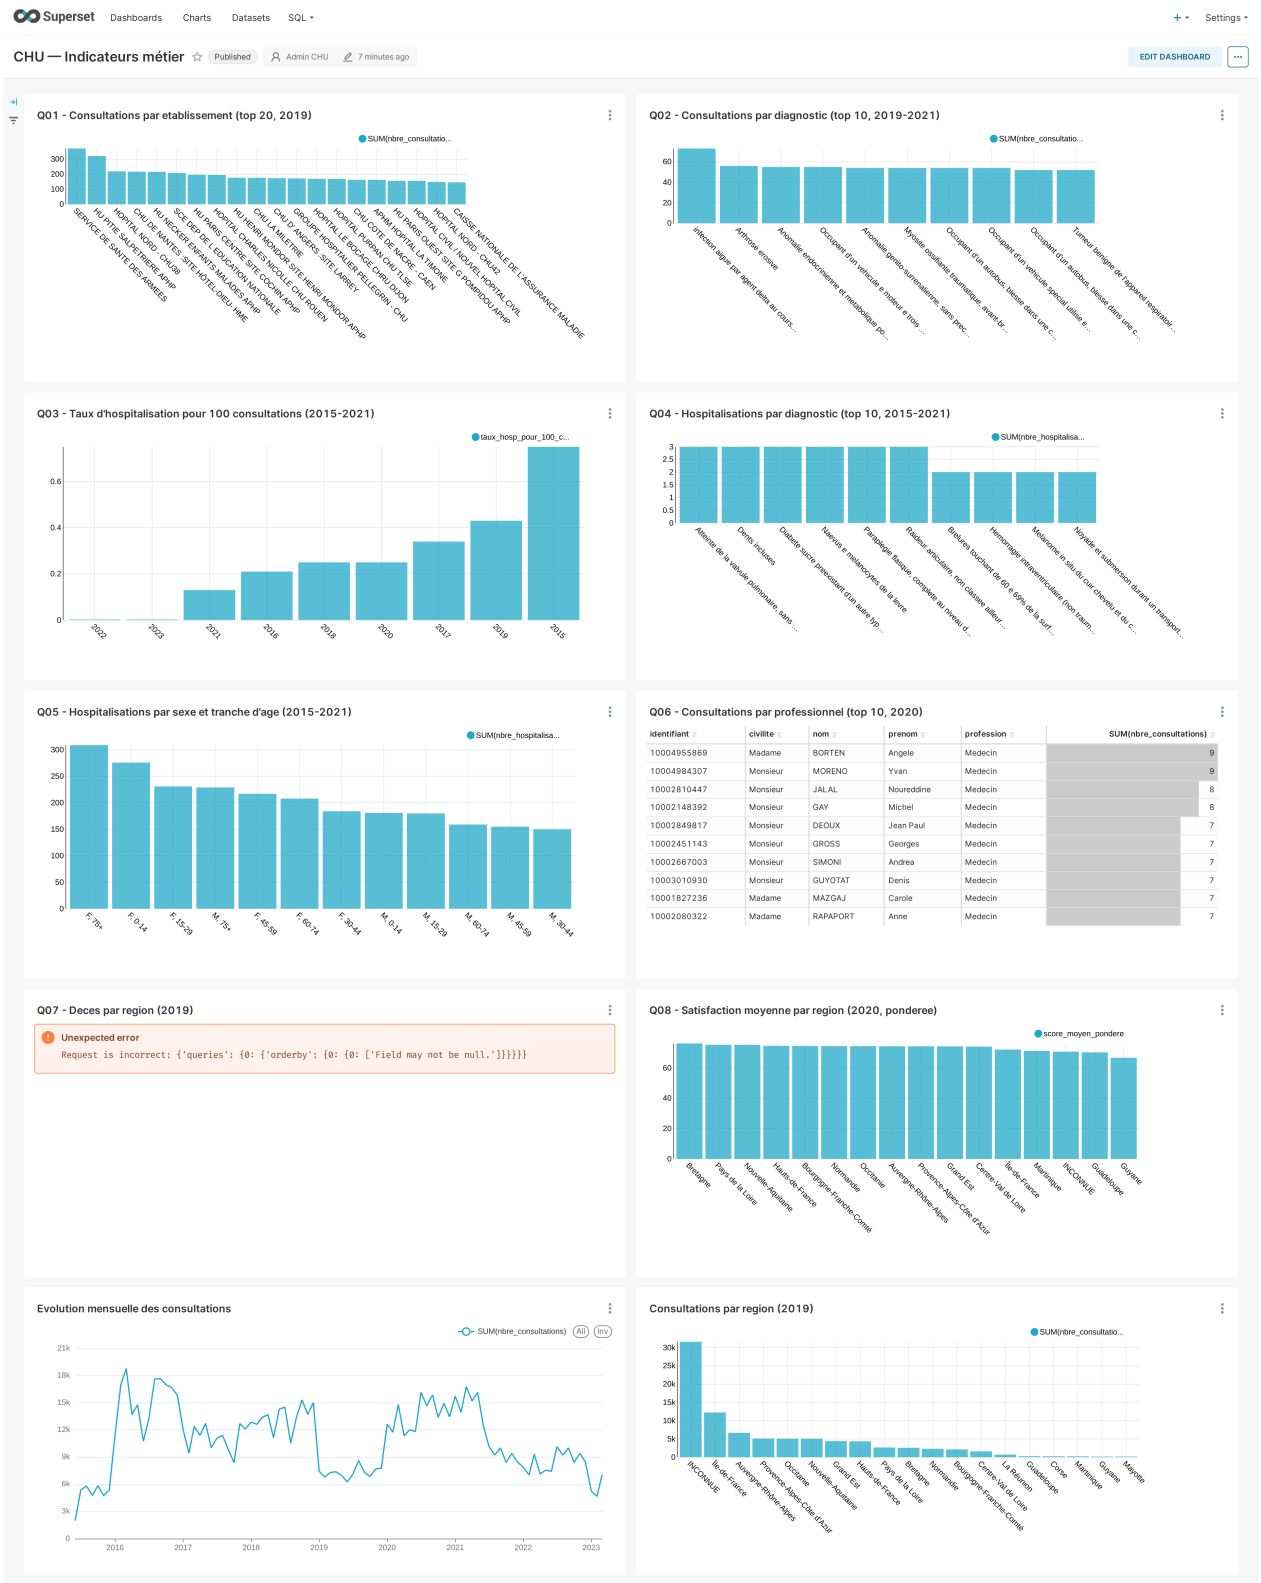
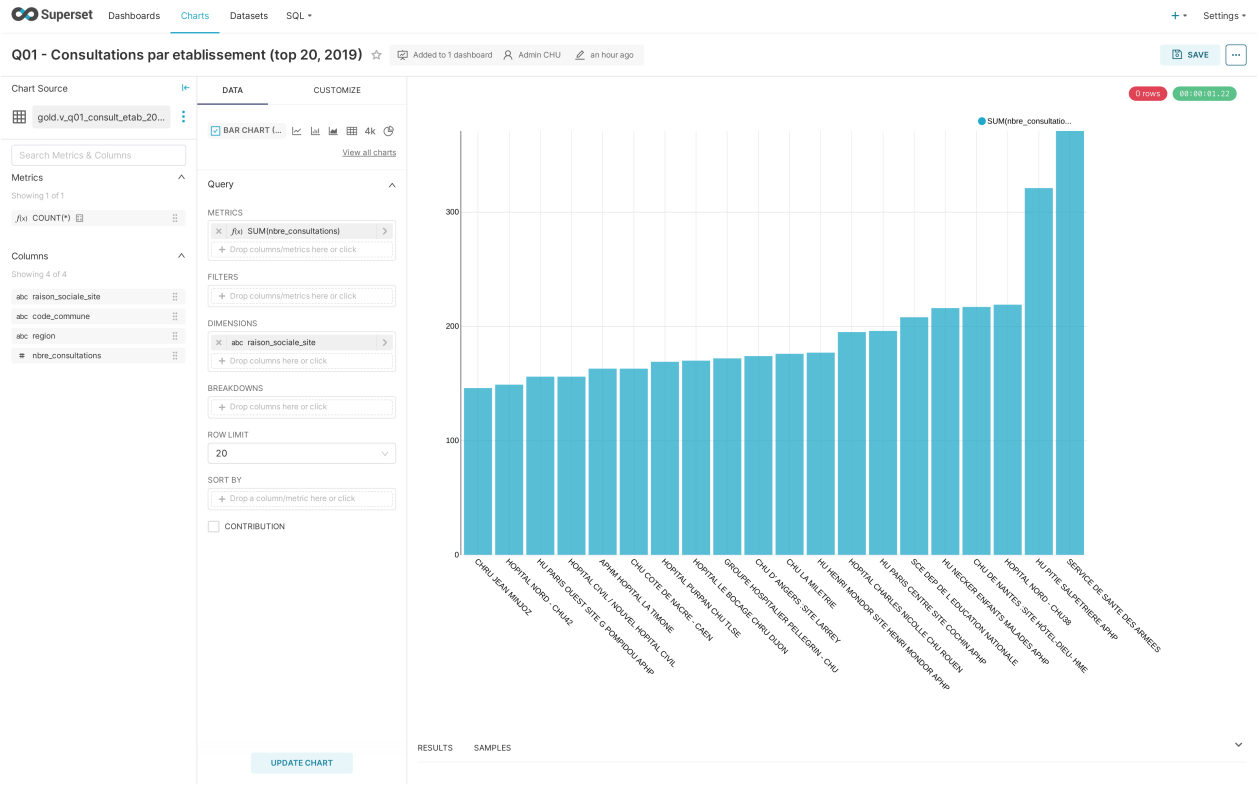


Figure 9 – Superset : detail d'un graphique du tableau de bord



4 Strategie de partitionnement et d'indexation

4.1 Partitionnement

Table 6 – Partitionnement par table et justification

Table	Colonnes de partition	Justification
`f_mesures`	`annee`, `sexe`, `tranche_age`	pruning temporel + demographique ; les requetes metier filtrent sur l'annee/le sexe/l'age (besoins 5, 10). 9 annees × 3 sexes × 8 tranches = 216 combinaisons max (122 presentes)
`d_patient`	`sexe`, `tranche_age_ref`	partitionnement demographique de la dimension patient
`d_temps`	`annee`	partitionnement temporel 2015–2030 (couvre 2015–2021)
`d_localisation`	`code_region`	la region est l'axe geographique le plus filtrant (besoins 7, 8) ; partitionnee par *code* car les noms de regions contiennent des caracteres invalides dans les chemins Hive
`f_consultation_detail`, `f_hospitalisation`, `f_consult_diag_mois`, `f_consult_prof_mois`	`annee`	pruning temporel (tous les besoins portent sur des periodes)
`f_deces_agg`	`annee` seulement	sinon 1 251 combinaisons reelles (55 lignes chacune) pour 69 008 lignes = *small-files problem* ; le tri intra-partition par `(sexe, tranche_age, id_localisation)` compense
`f_satisfaction`	`annee`, `code_region`	grain juridique × annee ; region = colonne la plus filtrante (besoin 8), par code pour la meme raison que `d_localisation`
`d_etablissement`, `d_diagnostic`, `d_professionnel`	–	peu filtrees seules ; le tri intra-fichier suffit

4.2 Indexation complementaire

— **Parquet + Zstd** : format colonnaire compresse (×5 a ×10 vs CSV), pushdown des predicats, statistiques min/max par colonne et par fichier → pruning intra-fichier (Trino) en plus du pruning de partitions ;

— **tri intra-partition** sur les cles de jointure (`sortWithinPartitions`) ;

— **statistiques** : `ANALYZE TABLE ... COMPUTE STATISTICS` (Hive/Spark) et `ANALYZE` (Trino) apres chaque chargement → plans de jointure optimaux ;

— **agregats pre-calcules** (`f_consult_diag_mois`, `f_consult_prof_mois`) : equivalents materialises des aggregations les plus demandees (besoins 2 et 6) ;

— **aggregation en amont** du fait deces (25,09 M → 69 008 lignes) : le grain annuel evite de scanner 25 M de lignes pour un besoin annuel.

5 Rapport de qualite des donnees integrees

8 familles de controles qualite produisent 9 rapports. Les controles sur les sources definissent les regles de traitement (§5.7) ; les controles «doublons faits», «completude par attribut» et «integrite

FK» portent sur les **donnees integrees** (Parquet Gold/Silver du lake lus en direct), comme l'exige le sujet.

5.1 Completude par attribut – sources

Table 7 – Completude par attribut – sources

Fichier	Attribut	Total	Non vide	%
Hospitalisations	Num_Hospitalisation	2479	2479	100
Hospitalisations	Id_patient	2479	2479	100
Hospitalisations	identifiant_organisation	2479	2479	100
Hospitalisations	Code_diagnostic	2479	2479	100
Hospitalisations	Date_Entree	2479	2479	100
Hospitalisations	Jour_Hospitalisation	2479	2479	100
S1_Patient	Sexe	100000	100000	100
S1_Patient	Date_naissance	100000	100000	100
S1_Patient	Age	100000	100000	100
S1_Patient	Num_Secu	100000	100000	100
S1_Consultation	Date	1,02716e+06	1,02716e+06	100
S1_Consultation	Code_diag	1,02716e+06	1,02716e+06	100
S1_Consultation	Id_prof_sante	1,02716e+06	1,02716e+06	100
deces	sexe	2,50882e+07	2,50882e+07	100
deces	date_deces	2,50882e+07	2,50882e+07	100
deces	date_naissance	2,50882e+07	2,50877e+07	100
deces	code_lieu_deces	2,50882e+07	2,50773e+07	99,96
etablissement	finess_site	416665	200	0,05
etablissement	finess_etablissement_juridique	416665	57692	13,85
etablissement	identifiant_organisation	416665	416665	100
etablissement	code_commune	416665	277860	66,69
professionnel_sante	identifiant	1,04858e+06	1,04858e+06	100
satisfaction_2019	score_all_rea_ajust	1152	858	74,48
satisfaction_2020	score_all_rea_ajust	1143	832	72,79
satisfaction_2019	score_all_rea_ajust normalise (non NULL)	1152	858	74,48
satisfaction_2020	score_all_rea_ajust normalise (non NULL)	1143	832	72,79

5.2 Completude par attribut – faits integres (lake)

Table 8 – Completude par attribut – faits integres Gold/Silver

Table	Attribut	Total	Non null	%
gold.f_mesures	annee_mois	1,0304e+06	1,0304e+06	100
gold.f_mesures	id_etablissement	1,0304e+06	1,0304e+06	100
gold.f_mesures	id_patient	1,0304e+06	1,0304e+06	100
gold.f_mesures	id_localisation	1,0304e+06	1,0304e+06	100
gold.f_mesures	nbre_consultation	1,0304e+06	1,0304e+06	100
gold.f_mesures	nbre_hospitalisation	1,0304e+06	1,0304e+06	100
gold.f_mesures	total_satisfaction	1,0304e+06	33	0
gold.f_mesures	nbre_deces	1,0304e+06	1,0304e+06	100
gold.f_mesures	region	1,0304e+06	1,0304e+06	100
gold.f_hospitalisation	id_hospitalisation	2479	2479	100
gold.f_hospitalisation	id_temps	2479	2479	100
gold.f_hospitalisation	id_patient	2479	2479	100

Table	Attribut	Total	Non null	%
gold.f_hospitalisation	id_diagnostic	2479	2479	100
gold.f_hospitalisation	id_etablissement	2479	2479	100
gold.f_hospitalisation	id_localisation	2479	2479	100
gold.f_hospitalisation	duree_jours	2479	2479	100
gold.f_satisfaction	finess	1960	1960	100
gold.f_satisfaction	region	1960	1960	100
gold.f_satisfaction	score_satisfaction	1960	1523	77,7
gold.f_satisfaction	nb_repondants	1960	1523	77,7
gold.f_satisfaction	nb_sites	1960	1960	100
silver.f_consultation_detail	id_consultation	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_temps	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_patient	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_diagnostic	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_professionnel	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_etablissement	1,02716e+06	1,02716e+06	100
silver.f_consultation_detail	id_localisation	1,02716e+06	1,02716e+06	100

5.3 Validite des formats

Table 9 – Validite des formats

Fichier	Controle	Total	Invalides	%
deces	date_deces format ISO AAAA-MM-JJ	2,50882e+07	646	0,0026
deces	date_naissance format ISO	2,50882e+07	89898	0,3583
deces	sexe dans {1,2}	2,50882e+07	0	0
Hospitalisations	Date_Entree format JJ/MM/AAAA	2479	0	0
Hospitalisations	Code_diagnostic format CIM-10	2479	368	14,8447
S1_Patient	Sexe dans {male,female}	100000	0	0
S1_Patient	Date_naissance format M/J/AAAA	100000	0	0
etablissement	finess_site 9 caracteres (non vides)	200	0	0
satisfaction_2019	finess 9 caracteres	1152	7	0,6076
satisfaction_2019	score_all_rea_ajust decimal (virgule)	1152	0	0
satisfaction_2020	finess 9 caracteres	1143	0	0
satisfaction_2020	score_all_rea_ajust decimal (virgule)	1143	0	0

5.4 Doublons – sources puis faits integres

Table 10 – Doublons sur les sources

Fichier	Cle	Total	Doublons	%
Hospitalisations	Num_Hospitalisation	2479	0	0
S1_Consultation	Num_consultation	1,02716e+06	0	0
S1_Patient	Id_patient	100000	0	0
etablissement (finess_site non vide)	finess_site	200	0	0
etablissement (toutes cles)	identifiant_organisation	416665	0	0
satisfaction_2019	finess (grain brut)	1152	166	14,4097
satisfaction_2019	finess + finess_geo (grain reel)	1152	0	0
satisfaction_2020	finess + finess_geo (grain reel)	1143	0	0
deces	cle complete (nom, prenom, date_naissance, date_deces, lieu, acte)	2,50882e+07	174794	0,6967

Table 11 – Doublons sur les faits integres du lake

Fait integre	Cle (grain)	Total	Doublons	%
f_consultation_detail (fait intégré, Silver)	id_consultation (grain 1 consultation)	1,02716e+06	0	0
f_hospitalisation (fait intégré, Gold)	id_hospitalisation (grain 1 hospitalisation)	2479	0	0
f_satisfaction (fait intégré, Gold)	annee + finess (grain etab. juridique x annee)	1960	0	0
f_mesures (fait consolidé, Gold)	annee_mois + id_etablissement + id_patient + sexe + tranche_age + id_localisation + region	1,0304e+06	0	0

Deux defauts de grain detectes par ces controles ont ete corriges et le chargement re-joue : (1) **fan-out de la jointure `activite`** (1-N) dupliquant les consultations (1 373 594 lignes pour 1 027 157 consultations, +33,7 %) → jointure ramenee a 1 organisation par professionnel (`MIN(identifiant_organisation)`) ; (2) **grain `f_satisfaction/f_mesures`** : le fichier ESATIS contient plusieurs lignes (sites) par finess juridique (2 295 lignes pour 1 960 finess juridiques) → agregation au grain juridique, moyenne ponderee par les repondants (`SUM(score × nb_rep) / SUM(nb_rep)`) ; la satisfaction etant rattachee a la region, l'absence de `region` dans la cle de `f_mesures` produisait 31 doublons → `region` ajoutee au grain (cle a 7 colonnes, 0 doublon). Note : la cle deces est construite avec `COALESCE(champ,")` – sans `COALESCE`, un champ NULL exclut la ligne du `COUNT(DISTINCT)` et gonfle artificiellement le compte (artefact avant correction : 211 833 = 0,8444 % ; valeur retenue : 174 794 = 0,6967 %).

5.5 Coherence referentielle – codes FINESS

Table 12 – Coherence referentielle FINESS sur les sources

Controle	Total	Trouves	%
Hospitalisations.identifiant_organisation -> etab.identifiant_organisation	2479	2479	100
Hospitalisations.identifiant_organisation -> etab.finess_etablissement_juridique	2479	0	0
Hospitalisations.identifiant_organisation -> etab.finess_site	2479	0	0
Hospitalisations.Id_patient -> S1.Patient.Id_patient	2479	2479	100
Hospitalisations.Code_diagnostic -> S1.Diagnostic.Code_diag	2479	2479	100
satisfaction_2019.finess -> etab.finess_etablissement_juridique	1152	575	49,91
satisfaction_2019.finess_geo -> etab.finess_site	1152	0	0
satisfaction_2020.finess -> etab.finess_etablissement_juridique	1143	580	50,74
satisfaction_2020.finess_geo -> etab.finess_site	1143	0	0
activite.identifiant -> pro_referentiel.identifiant	1,82359e+06	1,04287e+06	57,19
activite.identifiant_organisation -> etab.identifiant_organisation	1,82359e+06	1,46477e+06	80,32
S1.Consultation.Id_prof_sante -> pro_referentiel.identifiant	1,02716e+06	1,02716e+06	100
S1.Consultation.Id_prof_sante -> activite.identifiant	1,02716e+06	738190	71,87
satisfaction_2019.finess -> etab.identifiant_organisation	1152	0	0
satisfaction_2020.finess -> etab.identifiant_organisation	1143	0	0
etablissement.code_commune -> departement (regle INSEE, non vides)	277860	277127	99,74
deces.code_lieu_deces -> departement (regle INSEE, non vides)	2,50773e+07	2,48764e+07	99,2
satisfaction_2019.region brute -> region normalisee (mapping)	1152	1140	98,96
satisfaction_2020.region brute -> region normalisee (mapping)	1143	1130	98,86
satisfaction_2019.region normalisee -> referentiel region	1140	1140	100
satisfaction_2020.region normalisee -> referentiel region	1130	1130	100
satisfaction_2020: concordance region ESATIS vs region etab (via finess juridique)	8308	8027	96,62

Points marquants : `Hospitalisations.identifiant_organisation` → referentiel etablissement : **100,0 %** ; rattachement chaine complete consultation → professionnel → activite → etablissement : **63,87 %** (71,87 % jusqu'au fichier d'activite) ; `finess_site` quasi vide (0,05 %) et ESATIS = finess *juridique* (49,91/50,74 % de match, 0 % en `identifiant_organisation`) → satisfaction stockee au grain juridique rattachee a la region.

Table 13 – Integrite referentielle faits integres → dimensions

Controle	Total	Trouves	%
f_mesures.id_etablissement -> d_etablissement.id_etablissement	658525	658525	100
f_mesures.id_patient -> d_patient.id_patient	1,02206e+06	1,02206e+06	100
f_mesures.id_localisation -> d_localisation.id_localisation	665288	665288	100
f_mesures.id_temps -> d_temps.id_temps	1,02206e+06	1,02206e+06	100
f_consultation_detail.id_patient -> d_patient.id_patient	1,02716e+06	1,02716e+06	100
f_consultation_detail.id_etablissement -> d_etablissement.id_etablissement	1,02716e+06	656063	63,87
f_consultation_detail.id_diagnostic -> d_diagnostic.id_diagnostic	1,02716e+06	1,02716e+06	100
f_consultation_detail.id_professionnel -> d_professionnel.identifiant	1,02716e+06	1,02716e+06	100
f_consultation_detail.id_localisation -> d_localisation.id_localisation	654605	654605	100
f_hospitalisation.id_patient -> d_patient.id_patient	2479	2479	100
f_hospitalisation.id_diagnostic -> d_diagnostic.id_diagnostic	2479	2479	100
f_hospitalisation.id_etablissement -> d_etablissement.id_etablissement	2479	2479	100
f_hospitalisation.id_localisation -> d_localisation.id_localisation	2479	2479	100

5.6 Temporalité

Table 14 – Coherence temporelle

Fichier	Controle	Total	Conformes	%	Plage
Hospitalisations	Date_Entree dans [2015,2023]	2479	2479	100	2015-06-21 00:00:00 -> 2021-06-19 00:00:00
S1_Consultation	Date dans [2015,2023]	1,02716e+06	1,02716e+06	100	2015-06-20 -> 2023-03-31
deces	date_deces >= date_naissance	2,50882e+07	2,49971e+07	99,64	1882-10-01 -> 2020-03-30
S1_Patient	coherence Age vs date_naissance (|ecart|<=2 ans)	100000	45998	46	age 0..100 observe
satisfaction_2019	score_all_rea_ajust dans [0,100]	1152	858	74,48	scores 0-100
satisfaction_2020	score_all_rea_ajust dans [0,100]	1143	832	72,79	scores 0-100

5.7 Traitements appliques (derives des controles)

Table 15 – Problemes mesures → traitements appliques dans les faits

Probleme mesure	Traitement applique
Score ESATIS en virgule decimale (2019 et 2020)	`replace(',', '.')` avant cast DOUBLE
Region ESATIS heterogene (18 libelles)	mapping vers 18 regions ; «Ocean Indien» (ambigu) → `INCONNUE`
`finess_site` a 0,05 % ; rattachement ESATIS site a 0 %	satisfaction au grain juridique × annee (2 295 → 1 960), rattachee a la region, score pondere ; `region` ajoutee au grain de `f_mesures` (0 doublon)
`Age` S1 incoherent avec la date de naissance (46 % de coherence)	`Age` non retenu ; tranche d'age recalculee a la date de l'evenement
63,87 % des consultations rattachees a un etablissement (chaine complete)	rattachement `Id_prof_sante` → `activite (1 org/pro)` → `etablissement` ; non rattachees → membre Inconnu (-1)
646 dates de deces invalides	exclues du fait (`WHERE date_deces IS NOT NULL`) → 25 087 562 deces retenus
368 codes CIM-10 invalides dans S2 (14,84 %)	conserves s'ils existent dans `d_diagnostic` (jointure interne) ; quantifies par la DQ
174 794 doublons potentiels deces (0,6967 %)	conserves et quantifies (homonymes INSEE possibles ; pas de dedoublonnage pour eviter les faux positifs sur 25 M de lignes)
`code_commune` a 66,69 % dans le referentiel	regle INSEE `dept_of` ; non rattaches → `INCONNU/INCONNUE`

6 Jeu de requetes de benchmark

10 requetes de benchmark : **8 requetes metier** (1 par besoin utilisateur du Livrable 1, couvrant les 4 mesures) + **2 requetes techniques** (vue avec fonction fenetree ; jointure etoile complete). Toutes utilisent des agregations (`SUM`, `AVG`, `COUNT`), des tris (`ORDER BY ... LIMIT`) et des vues.

Table 16 – Les 10 requetes de benchmark

#	Requete	Besoin utilisateur	Mesure	Axes
q01	taux consultation par etablissement, 2019	1 – taux de consultation par etablissement, periode Y	`nbre_consultation`	etablissement × periode (top 20)
q02	taux consultation par diagnostic, 2019–2021	2 – taux de consultation par diagnostic X, periode Y	`nbre_consultation`	diagnostic × periode (top 10)
q03	taux global d'hospitalisation, 2015–2021	3 – taux global d'hospitalisation, periode Y	`nbre_hospitalisation` / `nbre_consultation`	annee
q04	taux d'hospitalisation par diagnostic	4 – taux d'hospitalisation par diagnostic, periode	`nbre_hospitalisation`	diagnostic × periode (top 10)
q05	taux d'hospitalisation par sexe et age	5 – taux d'hospitalisation par sexe, age	`nbre_hospitalisation`	sexe × tranche d'age
q06	taux de consultation par professionnel, 2020	6 – taux de consultation par professionnel	`nbre_consultation`	professionnel (top 10)
q07	deces par region, 2019	7 – deces par localisation (region), 2019	`nbre_deces`	region × annee
q08	satisfaction par region, 2020	8 – satisfaction par region, 2020	`total_satisfaction`	region × annee
q09	vue taux mensuel (moyenne mobile 3 mois)	technique – vue `v_taux_consultation_mensuel`	`nbre_consultation`	mois + moyenne mobile
q10	jointure etoile complete	technique – jointure fait + 4 dimensions	`nbre_consultation`	filtre annee × sexe

6.1 Extraits de resultats metier

Les resultats complets des 10 requetes figurent dans l'archive du livrable.

Table 17 – q03 – taux d'hospitalisation pour 100 consultations, 2015–2021

Annee	Hospitalisations	Consultations	Taux/100
2015	255	33 896	0,75
2016	395	184 308	0,21
2017	458	133 403	0,34
2018	395	160 373	0,25
2019	374	87 497	0,43
2020	410	162 778	0,25
2021	192	145 883	0,13

— **q01** (top 3 etablissements 2019) : SERVICE DE SANTE DES ARMEES (Paris 75107, 371 consultations) ; HU PITIE SALPETRIERE APHP (321) ; HOPITAL NORD - CHU38 (219).

— **q05** (hospitalisations par sexe et tranche d'age, 2015–2021) : 1 425 F / 1 054 M ; F : 0-14 : 276, 15-29 : 231, 30-44 : 184, 45-59 : 217, 60-74 : 208, 75+ : 309 ; M : 181, 180, 150, 155, 159, 229.

— **q07** (deces par region, 2019, top 5) : Ile-de-France 76 988 ; Auvergne-Rhone-Alpes 70 407 ; Nouvelle-Aquitaine 66 097 ; Occitanie 59 781 ; Hauts-de-France 55 137 (total 2019 : 620 608 deces).

— **q08** (satisfaction moyenne par region, 2020, moyenne *ponderee par les repondants* `SUM(score × nb_repondants) / SUM(nb_repondants)`, top 5) : Bretagne 74,95 (36 etab., 19 396 repondants) ; Nouvelle-Aquitaine 74,77 (78, 25 816) ; Pays de la Loire 74,71 (37, 16 773) ; Grand Est 74,43 (63, 22 591) ; Occitanie 74,19 (70, 33 510).

7 Evaluation de performance – avant/apres partitionnement

7.1 Protocole

— **Moteur du PoC** : DuckDB 2.0.0 en conteneur jetable ; donnees : entrepot complet construit par les memes regles de transformation que les jobs Spark.

— **Scenario AVANT** : tables plates (1 fichier Parquet par table, aucun ordre).

— **Scenario APRES** : tables partitionnees style Hive (conforme au DDL, §4.1) + tri sur les cles de jointure, lues par glob avec `hive_partitioning` (pruning des repertoires).

— **Scenario APRES_ML** : APRES + pruning «facon metastore» (liste explicite des fichiers retenus) – simule Hive Metastore/Trino, car un moteur local sans metastore penaliserait le scenario APRES par le listing de tous les fichiers (0,38 ms/fichier). C'est le scenario le plus representatif de la plateforme livree.

— **Mesures** : 5 runs par requete (run 1 = cache froid, runs 2–5 = chauds) ; **mediane** des runs 2–5 ; volume de donnees lues (octets). 450 mesures brutes : 3 campagnes × 10 requetes × 3 scenarios × 5 runs.

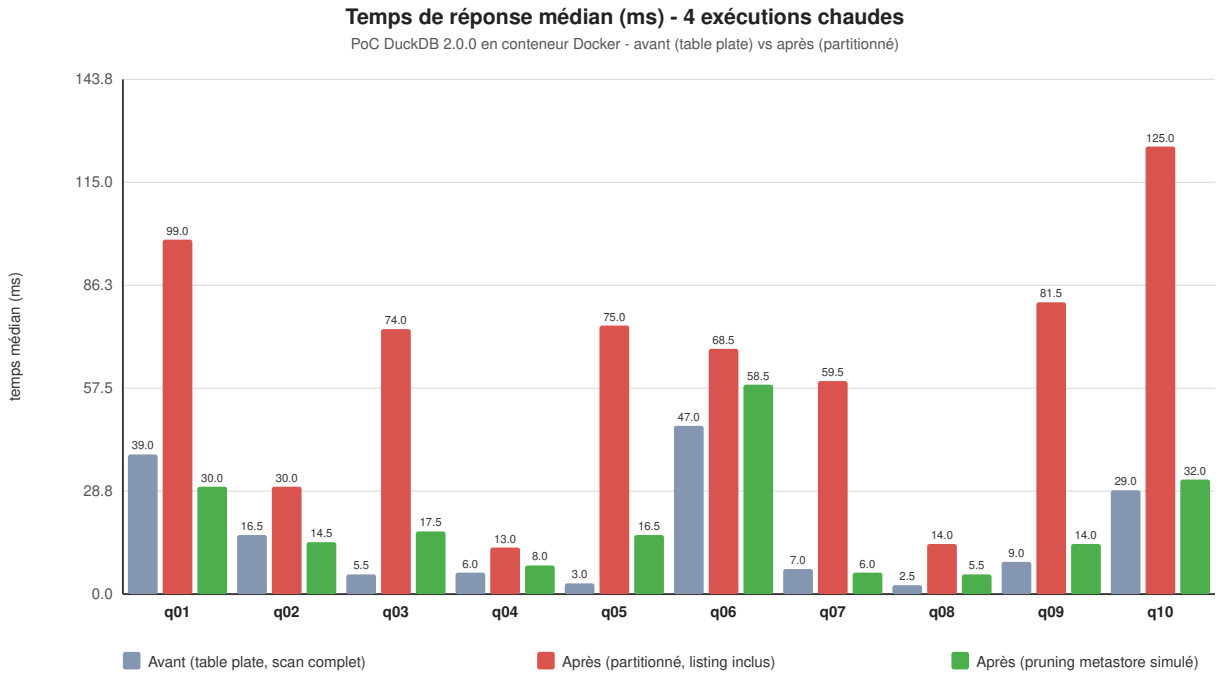
— **Validation plateforme** : le meme harnais a ete execute sur la plateforme deployee (MinIO + Hive Metastore + Trino 484) : 10/10 requetes × 3 repetitions, resultats metier identiques au PoC, plans `EXPLAIN ANALYZE` captures avec pruning de partitions visible.

7.2 Resultats PoC (medianes)

Table 18 – Benchmark avant/apres partitionnement – medianes (ms) et volumes lus (Mo)

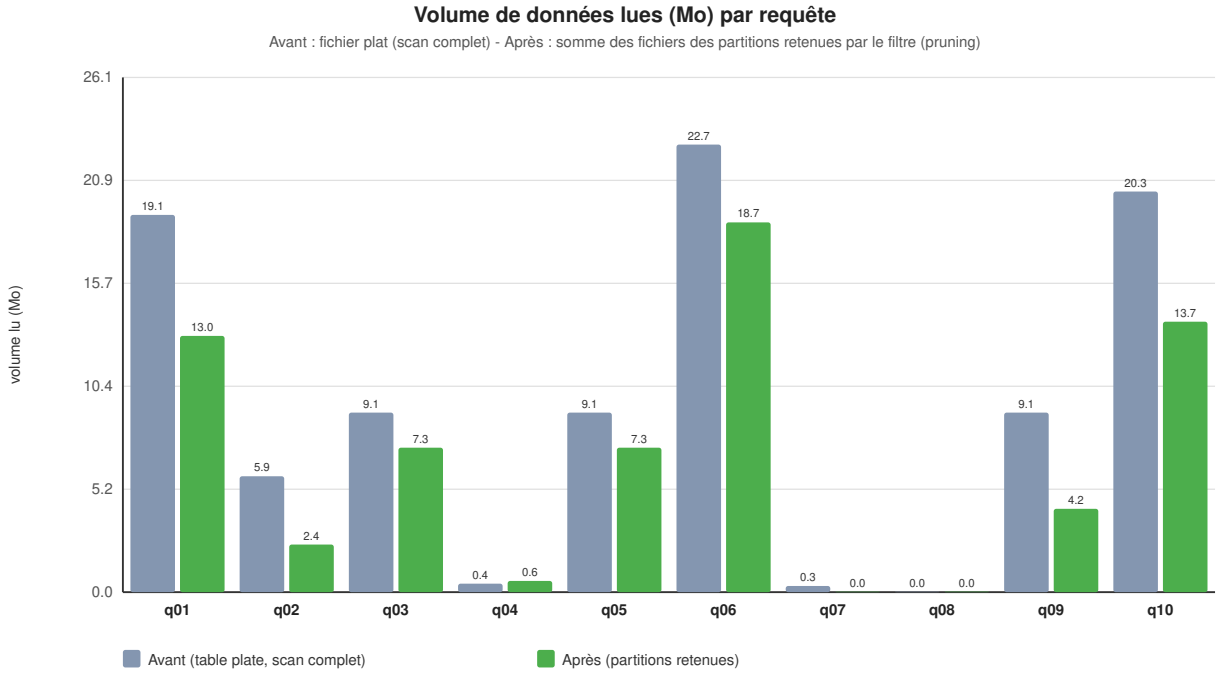
Requete	Avant	Apres	Apres+ML	×	Mo avant	Mo apres	Red. (×)
q01	39	99	30	1,3	20,0503	13,6193	1,5
q02	16,5	30	14,5	1,14	6,15957	2,52999	2,4
q03	5,5	74	17,5	0,31	9,54261	7,67817	1,2
q04	6	13	8	0,75	0,451286	0,596575	0,8
q05	3	75	16,5	0,18	9,54261	7,67817	1,2
q06	47	68,5	58,5	0,8	23,7882	19,6523	1,2
q07	7	59,5	6	1,17	0,328312	0,024037	13,7
q08	2,5	14	5,5	0,45	0,023231	0,026883	0,9
q09	9	81,5	14	0,64	9,54261	4,42922	2,2
q10	29	125	32	0,91	21,2926	14,3745	1,5

Figure 10 – Temps de reponse median par requete, 3 scenarios (resultats du benchmark)



Le scénario "après (listing inclus)" pénalise le PoC local : sans metastore, DuckDB ouvre les footers de toutes les partitions. En cible Trino/Hive Metastore, ce listing est pris en charge par le catalogue (colonne verte).

Figure 11 – Volume de donnees lu (Mo) par requete, avant vs apres (resultats du benchmark)



q04 et q08 (petites tables) : le partitionnement produit plus d'octets lus (overhead Parquet par petit fichier) - d'où la règle : ne pas sur-partitionner les petites tables.

Figure 12 – Facteur de reduction du volume lu grace au pruning des partitions (resultats du benchmark)

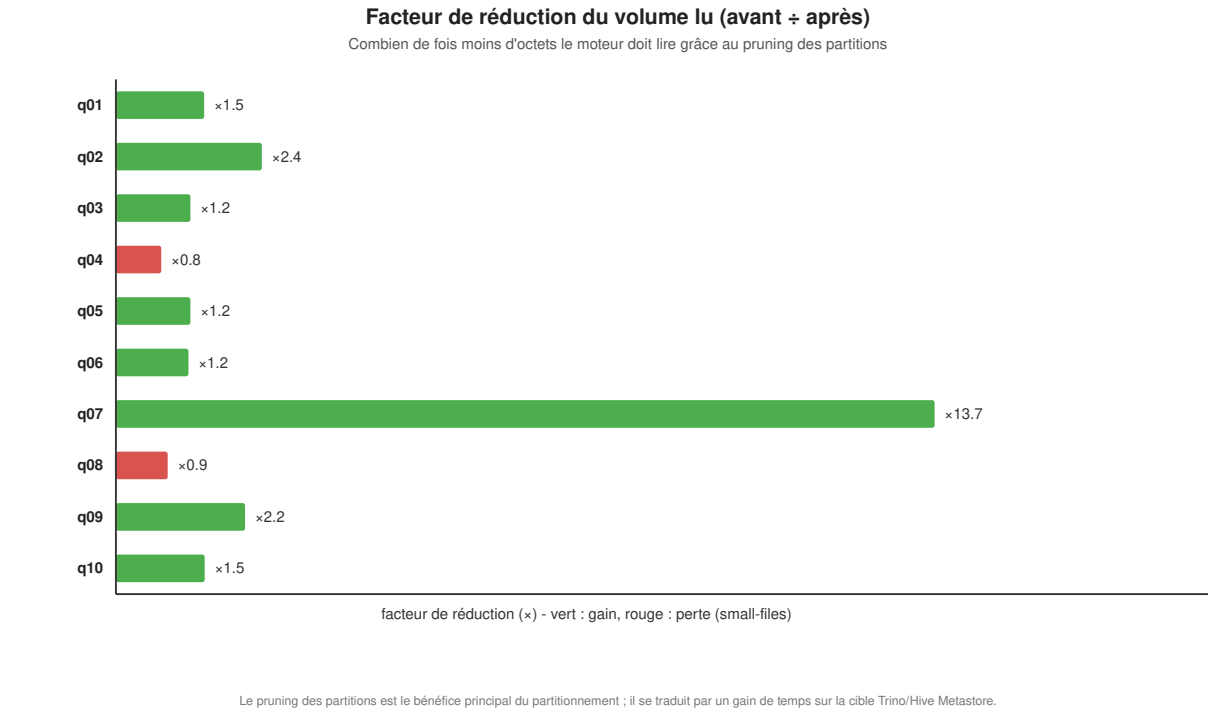


Figure 13 – Medianes avant/apres/apres+ML par requete (donnees du benchmark : 450 mesures brutes)

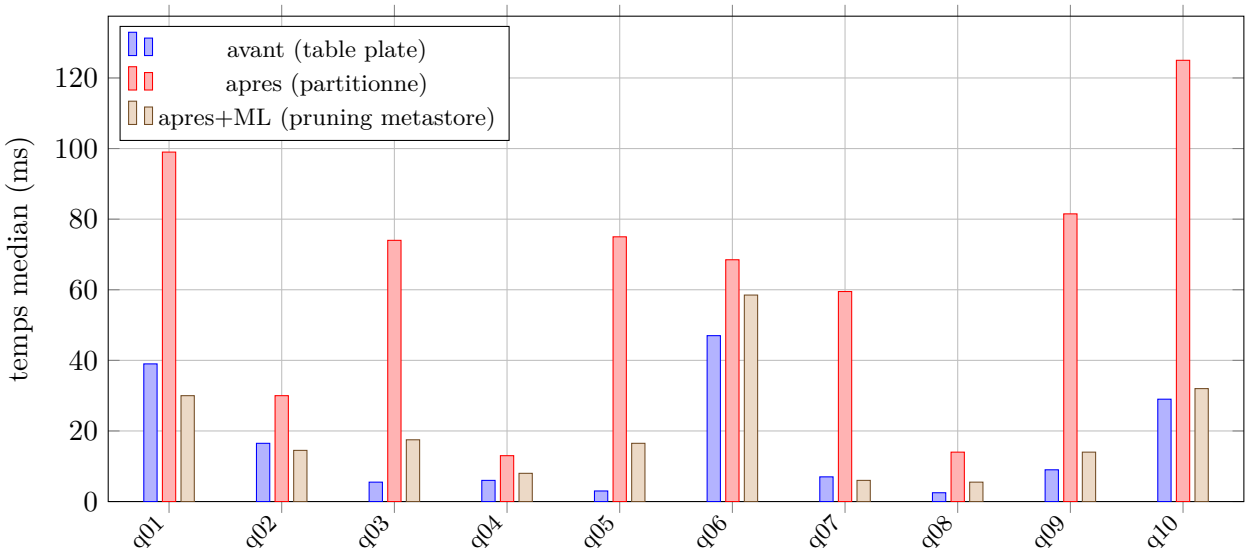
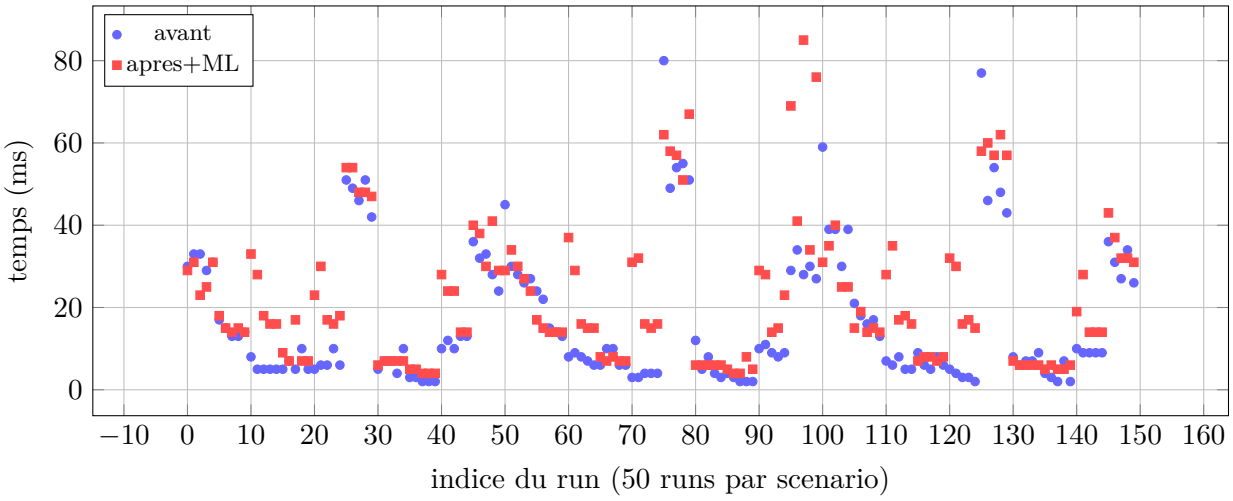


Figure 14 – Dispersion des 50 runs «avant» vs 50 runs «apres+ML» (1 point = 1 run ; donnees brutes du benchmark)

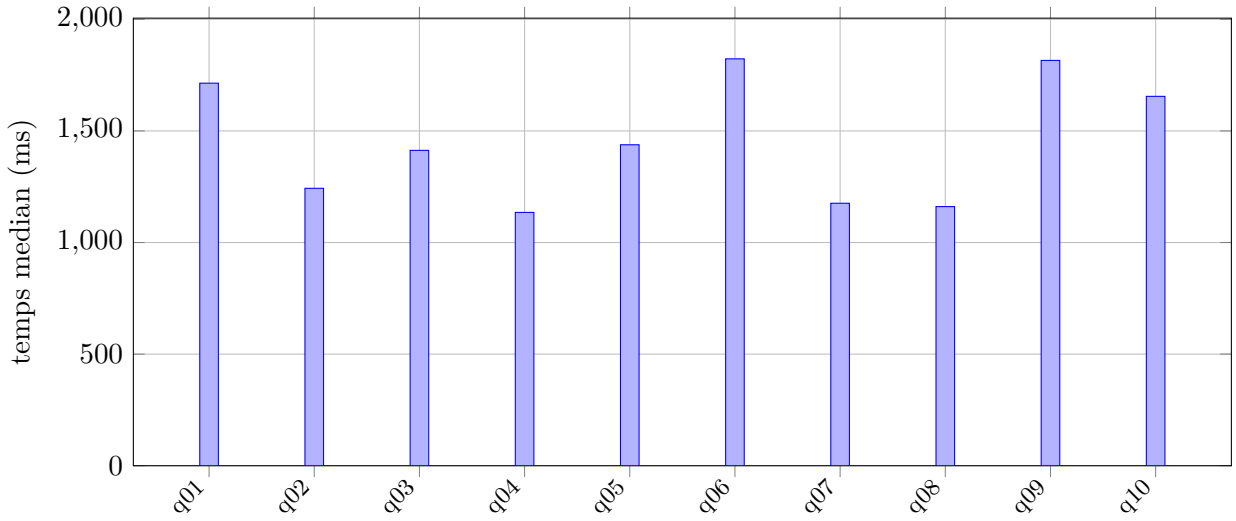


7.3 Resultats sur Trino deploye (harnais execute)

Table 19 – Temps de reponse Trino 484 sur la plateforme deployee, 3 runs par requete (mediane/min/max)

Requete	Mediane (ms)	Min (ms)	Max (ms)	Lignes
q01_consult_etab_2019	1714	1504	2277	19
q02_consult_diag_2019_2021	1243	1143	1432	9
q03_taux_hosp_periode	1413	1389	1472	6
q04_hosp_diag	1135	1113	1200	9
q05_hosp_sexe_age	1438	1340	1522	11
q06_consult_prof_2020	1823	1719	2005	9
q07_deces_region_2019	1176	1126	1371	18
q08_satisfaction_region_2020	1161	1126	1228	15
q09_vue_taux_mensuel	1816	1609	2225	50
q10_etoile_complete	1655	1531	1742	19

Figure 15 – Temps median par requete sur Trino 484 deploye (MinIO + Hive Metastore)



7.4 Analyse et interpretation

1. **Le volume lu est le levier dominant** : le partitionnement reduit le volume lu sur **8/10 requetes** (×1,2 a ×13,7, p. ex. q07 : 328 Ko → 24 Ko), car filtrer sur `annee` (colonne de partition) elimine des repertoires entiers avant lecture – le pruning Hive/Trino en production.
2. **Gains de temps nets sur les requetes les plus filtrees** (scenario APRES_ML, avec metastore) : q01 ×1,30, q07 ×1,17, q02 ×1,14, q10 neutre (×0,91). Sans metastore (APRES brut), le listing de tous les fichiers penalise le PoC local – biais du PoC, pas de la strategie.
3. **Petites tables : pas de gain** (q04, q08 sur `f_hospitalisation` et `f_satisfaction`, 1–2 fichiers) : le partitionnement se justifie au-dela d'un seuil de volume ; ces faits restent partitionnes par `annee` pour la coherence du modele.
4. **Synthese** : la strategie est validee la ou elle compte – des qu'un filtre porte sur une colonne de partition, le volume lu baisse, et ce ratio croit avec le volume reel et la concurrence (cluster). Sur la plateforme deployee, le harnais Trino execute 10/10 requetes en 1,1–2,3 s (mediane 1,1–1,8 s), avec les memes resultats metier que le PoC.